

Deep Research Arena

端到端评测流程说明

从沙箱、任务、跑 agent，到打分与上榜

内部说明文档（与仓库代码口径对齐）

日期：2026-07-09

Contents

Abstract

本文用白话把 Deep Research Arena (DRA) 从零到榜的完整流程写清楚：环境怎么搭、题怎么出、agent 怎么跑、报告怎么打分、榜怎么建，以及当前已知缺口。目标读者是项目成员与合作方，不要求先读完全部内部审计文档。文中公式与路径以仓库当前生产口径为准（truth 公式 K6；presentation 单列）。

1 一句话：我们在测什么

DRA 测的是：一个 Deep Research agent 能不能在**冻结的离线沙箱网页**里做跨站调研，并写出一份**带引用的长 Markdown 报告**；这份报告是否**站得住**（引用真实、事实可核对、覆盖关键信息），以及（可选地）读起来是否**有用**。

核心取舍：

- 不用开放互联网当主战场（网页会变，实验不可复现）。
- 用 WebArena 血统的购物站 + 论坛 + Wikipedia 快照，做成封闭世界。
- 接地（grounding）尽量用可判定规则打分，不靠 LLM 说「我觉得引用真」。
- 文采 / 有用性用陪审团（jury）另算，今天**不乘进**生产 truth 分。

2 总览：从头到尾九步

1. 搭沙箱（购物 / 论坛 / Wiki / 网关 / LLM 代理）
2. 建任务（intent）与答案键（answer key / golden）
3. 选 lane（12 个 agent 框架）与 backbone（底模）
4. 公平性协议检查（lane protocol + parity）
5. 跑一次任务：agent 搜、读、写报告
6. （理想）记录本次 run 的搜/读证据日志
7. 可判定打分：reach / fact / PoF / completeness / spec
8. 合成 truth，按 agent 聚合上榜；jury 另列
9. 站点发布与 changelog

下面按这个顺序展开。

3 第 1 步：沙箱环境

3.1 1.1 四个内容面 + 两扇门

服务	端口	作用
shopping (Magento)	7770	商品、价格、评分、评论
reddit (Postmill)	9999	论坛帖子、投票、讨论
wiki (Kiwix)	8090	百科文章快照
gateway / search shim	8081	搜索与取页入口；理想情况下所有搜/读都经这里
ds_proxy	8088	把各框架的 LLM 请求转到统一底模

关键性质：

- 语料冻结：购物/论坛数据烤进镜像；Wiki 用挂载的 .zim。
- 封闭世界：评测意图是 agent 只看见这些站点，不依赖当天的公网页面。
- 可复现：同一镜像 + 同一任务 + 同一打分代码，分数应可重放。

启动示例：

```
docker compose -f infra/sandbox.docker-compose.yml up -d
curl -fsS http://localhost:8081/healthz
curl -fsS http://localhost:7770/
curl -fsS http://localhost:9999/
curl -fsS http://localhost:8090/
```

3.2 1.2 为什么要有 shim

Shim 不是可有可无的代理，它是**观测与封闭**的关键：

- 搜索：POST /search (Tavily 等兼容接口，结果只来自沙箱语料)
- 读页：GET /fetch?url=... 或 POST /extract
- 跑次括号：POST /_mark 给请求打上 run_id

只有走 shim 的搜/读，才能写入 logs/fetch/<run_id>.jsonl，供后面的硬 PoF 使用。

4 第 2 步：任务与答案键

4.1 2.1 任务（给 agent 看的）

任务 JSON 在 data/tasks/deep_research/cross_site_deep/。agent 主要看到的是自然语言 intent，例如：围绕某类消费电子，综合购物站、论坛、百科，写一份带引用的市场情报报告。

设计原则：

- 题面尽量自然，不把「必须引用 60 个 URL」这类评分细则写进 prompt（避免教考试）。
- 配额、格式要求放在答案键的 spec_requirements 里，由打分器检查。

当前规模（口径见 README / manifest）：约 100 道 deep 任务中约 75 道可打分；另有对抗任务集，golden 尚未齐。

4.2 2.2 答案键 / golden（给打分器看的，agent 不应直接拿到）

两层真值：

A. 沙箱原生 DB Magento / Postmill 里的价格、评分、帖子分等，通过 src/golden/db_schema_map.py 与 db_verifier.py 查询核对。这是 fact 轴的硬依据。

B. Answer key（每题一份） 典型字段：

- relevant_set：相关商品/帖子/词条及 DB 事实
- vital_nuggets / useful_nuggets：报告应覆盖的要点（completeness 分母）
- spec_requirements：格式/体量等合规检查
- gold_contradictions / decidable_verdicts：跨站矛盾等（多数题仍空；当前不进 K6 truth，论文也不应主卖未建成的支柱）

构建路径概览：爬沙箱 → 生成 golden → curate / manifest 隔离噪声题 → 迁移/整理为 answer key。

5 第 3 步：选谁来跑 (lane × backbone)

5.1 3.1 十二条框架车道 (lane)

主要包括：deerflow、gpt-researcher、camel-ai、smolagents、langchain-odr、storm、ii-researcher、flowsearcher-ds、ldr、qx-agents，以及 CLI 类的 opencode、claude-code。

说明：

- 多数是开源 agent 框架；claude-code / opencode 是 CLI 产品，能力交付方式不同。
- 每条 lane 有 adapter (scripts/runners/、scripts/run_deep_task.py)，负责把统一任务接到该框架的 API/工具上。

5.2 3.2 底模 (backbone)

同一套 lane 可挂不同底模（如 qwen3-8b、deepseek-v4-flash），经 ds_proxy 统一出口。跨底模比较要求除权重外尽量一致（温度、最大输出、thinking 开关等）；当前 thinking 跨底模仍未完全齐平，属已知限制。

6 第 4 步：公平性协议

文件：config/lane_protocol.yaml。预检：python3 scripts/check_parity.py。

协议大意：

- 每条 lane 只拿共享 intent + 统一的「请交一份 Markdown 报告」说明。
- 禁止偷偷塞：引用数量、字数门槛、示例 URL、评分细则（除非在协议里声明偏差）。
- 禁止 harness 事后往报告里嫁接 URL、把公网链接改写成沙箱链接、按得分轴自动修报告。
- 历史硬作弊路径（如 ii 输出侧 URL graft、flowsearcher 注入同评测集 prior-run 记忆）默认关闭。

公平性解决的是「有没有偷偷喂答案」；**不等于**所有 lane 的搜/读能力交付已经完全同构（CLI 与 in-process 仍有差异）。

7 第 5 步：跑一次任务 (agent 执行)

入口通常是 scripts/run_deep_task.py（或各 runner）。一次 run 的理想过程：

1. harness 向 shim 发 /_mark start（带上 run_id、lane、task）
2. agent 反复：搜索 → 打开页面 → 记笔记 / 规划
3. agent 写出带引用的 Markdown 终稿
4. harness 保存报告；发 /_mark end

现实中常见偏差（重要）：

- **搜索**多数还能走 shim /search。
- **读页**很多框架用 requests.get / aiohttp / curl **直连** localhost:7770/9999/8090，不经 shim。
- 结果：页面可能真读了，但 logs/fetch 没有记录 ⇒ 「读页不可观测」。
- 这与「外漏到公网」不是同一件事：直连沙箱仍是封闭世界内抄近路；公网引用是另一类问题（reach / fabrication 会罚）。

弱报告、超时、卡死（stalled：长时间既无 LLM 调用也无 shim 调用）应诚实记录，避免把基建故障直接当成框架零分（策略上建议：重跑后仍 stalled 再计 0）。

8 第 6 步：证据日志（理想仪器）

有完整证据时，每次 run 可区分：

集合	含义
SEARCH_RETURNED	搜索结果里出现过的 URL
FETCHED	shim 实际取回成功的页面
CITED	报告里引用的 URL

由此可剥开：

- 真读过：CITED $\cap$ FETCHED
- 只靠搜索摘要：snippet_only
- 沙箱里有但既没搜到也没读过：hallucinated_grounding（偏参数记忆）
- 沙箱外：fabrication

实现：integrations/search_shim/evidence.py、src/eval/fetch_log.py。

现状：定义已有；主路径 /_mark 与各 lane 读页收敛尚未齐，故默认仍难全面启用硬 PoF。

9 第 7 步：可判定打分（对一份报告）

核心模块：src/eval/decidable_scorer.py。

输入：报告 Markdown、answer key、页面缓存（及可选 transport 证据）。

9.1 7.1 五条轴

1. **reach**：引用的 URL 是否属于封闭世界 / 可达。反编造门。
reach = 0 $\Rightarrow$ 后面 truth 必为 0。
2. **fact**：报告中的结构化声明（价格、评分等）是否与 DB / answer key 一致。
3. **PoF**：引用是否有「读过 / 内容支撑」证据。
默认 text_v1：报告上下文与评测方缓存页面做文本级匹配（更弱、更可复现）。
目标 transport_v2：引用是否出现在本次 run 的 FETCHED 集合（更硬）。
4. **completeness**：vital 要点覆盖了多少（nugget / vital pool recall）。
5. **spec**：格式与体裁合规。只进 **compliance** 列，不乘进 **truth**。

9.2 7.2 合成（生产公式 K6）

$$\text{quality} = 0.39 \cdot \text{fact} + 0.28 \cdot \text{PoF} + 0.33 \cdot \text{completeness}$$

$$\text{truth} = \text{reach}^\gamma \cdot \text{quality}, \quad \gamma = 1.5$$

要点：

- 乘法门：接地是必要条件，文采再好也不能用加法把 reach=0 救回来。
- 无 quality 地板（EPS_FLOOR=0）：避免空壳 / mini-shell 被垫高。
- 权重是声明的伤害序重归一，不宣称最优；应公开原始轴分并做敏感性分析。

对抗判据（结构上要守住）：

- C1：纯编造者不能得正 truth。
- C2：格式完美但零实质的空壳 truth = 0。

9.3 7.3 页面缓存从哪来

评测方根据报告中出现的 URL 构建 / 查询 sandbox HTTP cache(scripts/build_sandbox_cache.py 等)。

注意：这是「报告里写了什么 URL」，不等于「agent 当时取回过」。打分时 cache miss 不应再偷偷上网补抓（当前实现倾向拒绝现场补抓，避免仪器漂移）。

10 第 8 步：上榜与陪审

10.1 8.1 Truth 榜

scripts/build_truth_board.py:

- 对每个 (agent, task) 算 truth
- 按 agent 做宏平均等聚合
- 排序主键是 truth
- 可选 --panel 喂入 jury 分数：仅在 truth 几乎打平时破平局，**不进入 truth 数值** 板子带 protocols 版本戳（公式版本、extractor commit 等），跨版本禁比。

10.2 8.2 Usefulness / presentation (jury)

流程概览：

1. 同一任务上两份报告两两对战（常做位置对调）
2. 多判官投票（PoLL）
3. Bradley-Terry 拟合得到 Elo 或相对胜率

判官被要求评「对人是否有用」，**不要**评引用真假（那是可判定栈的工作）。
现状注意：

 - 生产 truth **尚未**乘上 judge Elo。
 - 若将来要合成，乘法更宜用 BT **胜率**（比例量表），不宜直接乘 Elo（区间量表）。
 - 历史 live 框架榜存在约 40.5% 单判官场次，不能当成干净三判官结果。
 - 候选 Arena = reach^γ × winrate 曾未通过门定理，补门前不上 headline。

10.3 8.3 旧公式（已退休，勿再引用）

早期对外叙述曾写：

$$\text{gated_score} \approx \text{judge_Elo} \times \frac{\text{reach}\% + \text{quote}\%}{200}$$

这已不是当前生产口径。请以第 7.2 节 K6 为准。

11 第 9 步：发布

1. 代码 / 数据变更
2. 写入 data/changelog.json
3. 构建前端：frontend/ → web/dist/
4. 提交并推送；Cloudflare 发布站点

公开站：<https://www.deepresearcharena.com/>

12 一张图串起来

```

[冻结沙箱] shopping / reddit / wiki
      ^
      | (理想: 只经 shim 搜/读)
      v
[agent lane] --intent--> 搜/读/写 --> report.md
      |
      | (理想: /_mark + fetch 日志)
      v
[decidable scorer]
  reach, fact, PoF, completeness, spec
      |
      v
  truth = reach^1.5 * quality
      |
      +-----> truth board (主排序)
      |
[jury 对战] --> presentation 列 / 破平局
      |
      v
      站点 leaderboard + changelog
  
```

13 当前已知缺口（读流程时必须知道）

1. **读页观测不全**：多数 lane 直连沙箱站点，shim 记不到 FETCHED；硬 PoF 不能对所有 lane 默认开启。
2. **默认 PoF 仍是 text_v1**：测「像不像页面」，不是「本次是否取回」；名实问题需在论文中正名或改仪器。
3. **/_mark 主路径未完全落地**：无 run 括号时证据无法归因，易静默退回旧度量。
4. **Elo 未乘进 truth**：与「gate × quality × Elo」的产品设想尚未在代码中闭合。
5. **跨站 contradiction 真值大量为空**：不进 K6；也不应作为主卖点，除非先建成。
6. **answer key 噪声**：自动爬 + 关键词相关集需 curate；商品名匹配等工程脆弱点仍在。
7. **jury 与对外文档**：单判官比例、README 旧公式等需持续对齐。

改善方向（摘要）：先给每次 run 打 /_mark；再按 lane 把读页收敛到 shim；smoke 验证 fetch 日志；最后默认 --require-transport-pof（接不上就报错，禁止静默降级）。

14 常用命令速查

```

# 公平性预检
python3 scripts/check_parity.py

# 跑单题（示意）
python3 scripts/run_deep_task.py --agent deerflow \
  --task dr_cross_deep_0010 --backbone qwen3-8b

# 建 truth 榜
python3 scripts/build_truth_board.py \
  --reports-dir path/to/reports \
  
```

```
--keys-dir data/golden/answer_keys \  
--cache path/to/sandbox_cache.json \  
--out truth_board.json  
  
# 强制要求 transport PoF (接线齐后再开)  
python3 scripts/build_truth_board.py ... --require-transport-pof
```

15 文档与代码索引

路径	内容
README.md	对外总览（已按 K6 更新）
config/lane_protocol.yaml	公平性与 fetch 可观测声明
src/eval/decidable_scorer.py	K6 打分
src/eval/fetch_log.py	transport 证据定义
scripts/build_truth_board.py	truth 榜
scripts/run_usefulness_jury.py	有用性陪审
docs/LANE_FAIRNESS_AUDIT_*.md	车道公平性审计
internal/docs/FORMULA_LOCK_*.md	公式定稿（维护者）
internal/docs/FETCH_PATH_AUDIT_*.md	取页路径审计（维护者）

16 结语

DRA 的完整故事不是「让模型写一篇漂亮长文」，而是：

在冻结世界里做调研 → 留下可检查的引用与事实 → 用可判定仪器量接地 → 用陪审另量有用性 → 诚实披露仪器边界。

今天流程的骨架已经打通；最大的工程与方法学缺口，是把「读页」真正收进可归因的观测管道，让 PoF 从文本相似升级为取回证据。在此之前，对外叙述应与仪器能力严格对齐，避免名实不符。

本文档由仓库当前代码与审计材料整理，日期 2026-07-09。若与后续 commit 冲突，以代码与 FORMULA_LOCK / lane_protocol 为准。