


DRA Query 与环境扩容规划

基于现有沙盒的 vNext 路线图

Commerce · Community · Wikimedia

Science/Technical · Travel/Geo · Public Statistics



Codex × Kimi 独立评审合并版

2026-07-30 · Planning Draft v1.0


状态：规划文档；不构成正式 benchmark release 或 leaderboard claim

目录

一页决策图	2
执行结论	3
一、规划依据与联合评审	3
二、现有沙盒与工程状态	4
2.1 已有世界资产	4
2.2 E1 / E2 最近状态	4
2.3 评分管线的真实成熟度	4
三、为什么不能直接扩写现有 56 题	5
3.1 题库结构过窄	5
3.2 Query 过长并泄漏证据边界	5
3.3 TWM 与 RTS 是复制层，不是可执行研究合同	5
3.4 人工治理状态不可重放	6
四、正式决策：修复线与扩容线并行	6
4.1 修复线	6
4.2 扩容线	6
五、环境 scale-up 计划	7
5.1 E1：完成现有世界编译基础	7
5.2 E2：Wikimedia W1M / Wfull	7
5.3 E3：Commerce / Community 全量重建	8
5.4 E4-A：Science / Technical Pack	8
5.5 E4-B：Travel / Geo Pack	8
5.6 E4-C：Public Statistics Pack	9
5.7 E5：统一交付合同	9
六、题库目标与配额	9
6.1 题库漏斗	9
6.2 Formal-60 vertical 配额范围	10
6.3 Formal-60 research-shape 目标	10
6.4 现有沙盒立即可拓展的主题	10
七、Query vNext 规范	11
7.1 公开 Query	11

7.2 私有 Blueprint / Task Contract	11
7.3 Query 泄漏检查	11
7.4 反模板与自然性	11
八、从候选题到正式题的 Release Gates	12
九、六个月路线图	12
M1: 止损、正名与基础门	12
M2: 现有世界 scale-up	12
M3: Compiler 重建	13
M4: 新垂直 MVP	13
M5: 候选题漏斗与交付合同	13
M6: 冻结与发布准备	13
十、人员、产能与成本	13
10.1 人工角色	13
10.2 人时规划	14
10.3 计算成本	14
十一、硬停机条件	14
十二、明确不做	15
十三、交付物清单	15
环境	15
Query 与任务	15
验证与发布	16
十四、成功标准	16
十五、状态命名	16
内部参考	16

一页决策图



硬原则：环境 scale-up 可以并行推进，但新 pack 未过 rights、coverage、agent-visible surface 与 delivery lineage 门之前，不得贡献正式题；ValidityGate 或 CapacityGate 失败时，应缩小 Formal 数量，不得降低标准。

执行结论

当前 DRA 需要同时解决两个问题：

1. 现有 Truth56 的 query、Task World Model (TWM) 与 Research Test Suite (RTS) 不是可继续横向复制的正式基线；
2. 现有沙盒规模很大，但研究垂直、来源角色、交互形态和正式构题能力尚未同时过门。

本规划采用两条并行路线：

- **修复线**：冻结旧结果，清除 query 中的证据泄漏与评分边界，重建公开/私有资产边界、人工治理链和 TWM/RTS compiler；
- **扩容线**：完成现有 Commerce、Community、Wikimedia 的 scale-up，并新增 Science/Technical、Travel/Geo，随后增加 Public Statistics pack。

六个月的目标不是“把编号写到 100”，而是形成一个经过淘汰和门控的题库漏斗：

180 个场景/Blueprint intake
→ 140 个 answerability candidate
→ 110 个完整 pipeline candidate
→ Dev-20 + Formal-60 + Reserve-16

Formal-60 是第一版的容量上限，不是必须凑满的配额。若 ValidityGate 或 CapacityGate 未通过，应缩小正式集，不得降低标准。完成首版冻结并获得真实人时、分歧率、FRR/FAR 与运行成本后，再决定是否扩到 Formal-100+。

一、规划依据与联合评审

本规划基于 2026-07-30 对以下本地资产的只读核查：

- data/tasks/deep_research/v3/ 的 57 个 v3 task；
- data/results/truth56_full_20260727/assets/ 的 56 个 transition asset；
- data/pilot_v33/dra_v3_dev_audio_0002/ 的完整单题切片；
- data/golden/url_registry.json 的沙盒 census；
- E1、E2 runbook、Query 人工治理流程和 sandbox-native scoring design。

Codex 与 Kimi Code 分别进行了独立审计。双方共识如下：

1. 不能在当前 transition builder 上直接追加题目；
2. query 修复与环境扩容应并行，而不是互相等待；
3. 新 pack 可以进入规划，但必须先完成 pack-level rights、coverage、surface 和 delivery gate；
4. 题库规模必须由完整 pipeline 的真实吞吐量决定；
5. 现有结果必须保留为历史诊断，不得静默覆盖或冒充正式集。

双方最初的主要分歧是正式集规模。Codex 的初始设想是 Formal-100；Kimi 指出，目前只有 audio_0002 展示了完整的 5 facets / 8 units / 25 checks / 20 evidence contracts 闭环，现有 56 题又全部为 diagnostic_transition。因此本规划采用：

- 首版冻结目标: **Formal-60**;
- 长期容量目标: **Formal-100+**;
- 是否晋级由 Dev-20 上实测的 ValidityGate、CapacityGate 和人时决定。

二、现有沙盒与工程状态

2.1 已有世界资产

- **Commerce / Magento**: 104,368 products; 用于商品、规格、价格、卖家主张、评论与分类。
- **Community / Postmill**: 127,391 submissions、95 forums; 用于社区经验、冲突、时间与群体偏差。
- **Wikimedia / Kiwix**: 19,551,505 user entries、48.4 GB ZIM; 用于百科背景、机制、历史叙述与跨页链接。
- **URL registry**: 104,368 product slugs、127,391 submission IDs、Wikipedia bloom; 用于闭世界成员与 URL 完整性。
- **Search / browse**: search shim、MCP、URL fetch、Kiwix 页面; 用于 Agent-visible discovery 和读取。
- **Counterfactual asset**: wiki_overlay; 用于参数记忆与证据依赖诊断。

Postmill 的现状需要专门澄清: 旧 DATASHEET 将论坛描述为“tech-only”, 但当前 registry 显示 95 个 forum, 包含 askreddit、news、personalfinance、science、food、多个地区板块等。它不是严格的纯技术语料, 但消费主题的覆盖深度非常不均衡:

- 较强: headphones、mechanicalkeyboards、gaming、consoles、iphone、technology、science、buyitforlife;
- 较弱或缺失: coffee、tea、photography/camera、furniture/chair;
- generic food 不能自动替代 chocolate/snacks 的同类经验。

因此, 必须先生成正式的 Forum Coverage Census, 不能继续根据旧文档或关键词命中决定每题是否需要社区角色。

2.2 E1 / E2 最近状态

- E1 已完成稳定 1- E2 W100K v2 已扫描全部 19,551,505 entries, 实际编译 99,810 documents, 并通过 identity、round-trip、BM25、resource 与恢复门;
- 文档记录 W1M 已启动, Wfull 与 E2 stage certificate 尚未完成;
- 这些大规模产物不在当前开发机上, 正式规划必须把构建主机、artifact mirror、恢复路径和 SHA-256 验证写入运行手册。

2.3 评分管线的真实成熟度

目前只有 dra_v3_dev_audio_0002 展示了接近目标架构的完整垂直切片:

- 5 facets;
- 8 research units;
- 25 executable checks;
- 20 evidence contracts;
- oracle、对抗报告与 release gate 资产。

Truth56 的 56 个 transition 资产则全部写明：

```
status = diagnostic_transition
formal_eligible = false
report_visible = false
```

因此, audio_0002 应作为 compiler 与 release-gate 的工程参考；Truth56 只能作为旧题诊断和 regression pool。

三、为什么不能直接扩写现有 56 题

3.1 题库结构过窄

Truth56 实际由 16 个 development task 和 40 个 formal/candidate task 构成，并不是“56 个独立正式题”。其 motif 分布为：

Motif	数量
multi_branch_synthesis	27
constraint_match_and_select	21
causal_or_evolution_explanation	8
claim_verification	0
evidence_reconciliation	0

全部任务仍是消费购买或购买后的测试决策。即使题目标题发生变化，核心研究行为仍集中在“比较商品—解释规格—建议购买或 defer”。

3.2 Query 过长并泄漏证据边界

57 个 v3 task 的 query 中位长度约 515 英文词，最长约 1,289 词。正式题平均约 4,450 字符。常见问题包括：

- 在题干中列出多个冻结价格、评分、SKU 和规格；
- 直接告诉 Agent 某两个字段存在冲突；
- 把“不能如何推断”的评分边界列成十余条；
- 给出盲测阈值、成本停止线和最终决策算法；
- 重复使用“do not treat”“do not infer”“or defer”等模板。

这会把“发现并审计证据”的研究任务改造成“按照已给审计清单复述”的指令遵循任务。

3.3 TWM 与 RTS 是复制层，不是可执行研究合同

Truth56 的 56 个 TWM 全部满足：

```
relations = []
conflict_clusters = []
bounded_unknowns = []
```

其 assertion 来自冻结 case evidence catalog 的字段扩展，而不是从完整 World Index 通过 query-only probes 构建。RTS 共 310 个 facet，全部是：

```
1 facet → 1 unit → 1 check
```

并且：

```
evidence_contracts = []
search_certificates = []
full_pass_contract = {}
```

这意味着当前批次无法验证替代证据、替代路线、依赖链、冲突、bounded absence 或细粒度部分完成。

3.4 人工治理状态不可重放

Task 文件中虽然写有 `query_validation.disposition=accepted` 和 blind review hash，但仓库中没有对应的完整阶段资产：

```
01_source_selection.json
03_evidence_review_decisions.json
05_graph_annotation.json
attempt_N.blind_packet.json
attempt_N.blind_review.json
query_release.json
```

因此，现有 validation 记录不能证明执行过 human query pipeline。新版本必须以“阶段资产存在且 hash 可重放”为准，不能以 task 文件里的自我声明为准。

四、正式决策：修复线与扩容线并行

4.1 修复线

立即执行，不依赖 E1/E2：

1. 将 Truth56 正名为 `candidate_pool_v0_diagnostic_transition`；
2. 冻结旧 query、case、运行结果和 hash，不原地覆盖；
3. Agent-facing public task 只保留自然 query 和必要运行元数据；
4. `generator_view`、candidate actions、evaluator view、oracle、acceptable conclusions 全部进入 private construction plane；
5. 建立 query leak linter、模板相似度检测、公开/私有资产 CI 门；
6. 建立真实 reviewer roster 和角色互斥规则；
7. 从旧 100 个 `cross_site_deep` 自然 query 中回收用户场景，但只把它们作为 scenario seed，旧 golden 不得直接晋级。

4.2 扩容线

环境扩容采用以下顺序：

```
E1 完成人工审计
├──→ E3 Commerce / Community 全量重建
├──→ TWM / RTS compiler 三题 smoke
└──→ existing-world Query MVP

E2 W1M → Wfull → E2 certificate
```


└─→ Wikimedia 全量 query-only candidate pools

E4-A Science / Technical

- └─ IETF RFC / official technical corpus
- └─ license-filtered PMC OA + metadata construction sidecar

E4-B Travel / Geo

- └─ Wikivoyage
- └─ regional OSM / GeoNames + local route/place renderer

E4-C Public Statistics

- └─ 一个许可清楚、口径可冻结的政府或国际组织数据 pack

E5 unified Search / Browse / Interaction + delivery lineage

E4-A 与 E4-B 的 acquisition、rights、PII 和 renderer 设计可以立即并行启动，不必等 E1/E2 全部完成；但它们的 task 不得进入正式题库，直到 pack certificate 和 delivery surface 过门。

五、环境 scale-up 计划

5.1 E1：完成现有世界编译基础

交付物：

- 完成人工审核字段；
- E1 stage certificate；
- compact store rebuild instructions；
- artifact mirror 与 SHA-256 表；
- parser error strata 与修复记录。

硬门：

- 任一高风险 parser family 出现系统性语义丢失，停止 TWM rebuild；
- canonical block 无法回到 agent-visible 页面，停止；
- 人工审核与自动 quality report 不一致时，先修 compiler。

5.2 E2：Wikimedia W1M / Wfull

交付物：

- W1M、Wfull manifests；
- checkpoint/recovery 记录；
- native Kiwix、canonical artifact、debug HTTP 三方 round-trip；
- exact alias、BM25、resource、table 与 redirect census；
- E2 stage certificate。

硬门：

- 不允许跳过失败 entry;
- 不允许把 W100K 结果外推为 Wfull PASS;
- Wikidata 只作 construction sidecar, 未通过 agent-visible surface 的内容不能支持得分。

5.3 E3: Commerce / Community 全量重建

交付物:

- Magento DB → canonical artifact → source-native HTTP 三方对齐;
- Postmill submission/post/reply/quote/time/author 结构;
- 商品 category/variant/price/review census;
- 95 个 forum 的主题覆盖、时间跨度、长度和重复簇报告;
- forum-topic answerability matrix。

硬门:

- query-conditioned inclusion 必须为零;
- 同名商品 variant 不得静默合并;
- 论坛引用与回复作者不得错归;
- task witness 只能在 build 完成后作为 recall probe。

5.4 E4-A: Science / Technical Pack

最低组成:

- 一个 official bulk / standards corpus;
- 一个许可允许的论文全文子集;
- 一个仅供 construction 的 metadata/citation sidecar;
- 论文 section、table、caption、citation anchor 的结构化 renderer。

必须证明的新能力:

- claim-method-measurement-limitation audit;
- 跨规范版本或跨论文方法综合;
- primary/official 与 secondary/encyclopedic source-role 区分。

5.5 E4-B: Travel / Geo Pack

最低组成:

- Wikivoyage;
- 一个预注册区域的 OSM/GeoNames;
- place、route、geometry、season/opening condition 的本地 surface;
- text API 与 browser/map/list 的 bridge manifest。

必须证明的新能力:

- 空间约束规划；
- 多地点组合与路线比较；
- 时间、季节、开放条件和地理范围的联合判断。

5.6 E4-C: Public Statistics Pack

初版只选一个许可清楚、版本稳定的数据源，不追求多机构规模。必须保存：

- 原始 CSV/JSON；
- table header、unit、region、time、missing value；
- 数据版本和修订语义；
- 可浏览表格与结构化 API 的等价映射。

必须证明的新能力：

- 跨表单位/口径对齐；
- 时间和地区聚合；
- 对缺失值、修订和不可比统计的 bounded conclusion。

5.7 E5: 统一交付合同

任何 pack 进入 formal 前必须证明：

```
raw source
→ canonical artifact
→ source-native / registered delivery transform
→ delivered artifact
→ observation ledger
```

不同 harness 不要求像素或工具序列相同，但必须获得等价的核心证据和结构。不能捕获实际交付内容的 adapter 只能进入 report-only lane。

六、题库目标与配额

6.1 题库漏斗

阶段	目标数量	说明
Scenario / Blueprint intake	180	人工场景、旧自然 query seed、新 pack blueprint
Answerability candidates	140	通过来源角色、候选池和最小 witness 门
Full-pipeline candidates	110	完整 evidence review、annotation、RTS、oracle、blind review
Dev	20	compiler、matcher、query round-trip 和产能校准
Formal vNext	最多 60	首版固定分母
Reserve	16	erratum、版本迁移、held-out route 与替换
Rejected / held out	至少 44	保留失败理由，不隐藏淘汰历史

6.2 Formal-60 vertical 配额范围

配额采用范围而非强制填格。若某 vertical 的 pack 或 answerability 不过门，正式数应减少。

Research vertical	目标范围
Consumer / services / technology decision	18–22
Science / technical synthesis	10–14
Travel / geography planning	8–12
Public data / policy interpretation	6–10
General knowledge / history / standards	6–10

控制规则：

- 任一 vertical 不超过正式集的 35- 至少 10 个独立 topic/blueprint cluster；
- 同一核心 evidence subgraph 最多进入 2 个 formal task；
- dev 与 formal 不能只通过改 cluster 名称实现“分离”。

6.3 Formal-60 research-shape 目标

Research shape	目标数量
Multi-option comparison / constraint decision	12
Claim / mechanism audit	10
Evidence reconciliation / conflict / uncertainty	10
Causal or evolution explanation	8
Tutorial / action plan / budget allocation	8
Bounded enumeration	6
Cross-page aggregation	6

这些是 portfolio 目标，不是为单题强行制造结构的模板。Evolution 必须先通过冻结世界内的日期声明数量、时点数和来源角色门；不达门时应声明 `unsupported_in_this_world_version`。

6.4 现有沙盒立即可拓展的主题

不等待新 pack，也可以从当前 104k 商品、95 个 forum 和 Wikipedia 中增加：

- 工具、DIY、维修性与 BIFL；
- home office、桌面、人体工学和空间约束；
- kitchen appliance、烹饪工具与维护；
- footwear、bags、outdoor gear、wearables；
- personal finance 与预算决策（forum + Wikipedia，不强制商品页）；
- machine learning、science、technology、space 的机制与证据协调；
- art、media、regional community 的跨页叙事综合；
- Magento category 上的 bounded enumeration 和 cross-page aggregation。

旧 `cross_site_deep` 的 100 个自然 query 覆盖了 headphones、smartphones、gaming、tools/BIFL、footwear、office、kitchen、bags、wearables 等 13 个 cluster。它们可以提供更自然的用户场景，但必须重新生成 Task Contract、TWM、RTS 和 answerability certificate，不能复用旧关键词 golden。

七、Query vNext 规范

7.1 公开 Query

默认要求：

- 120–300 英文词；
- 特殊复杂题最多 450 词，需独立审批；
- 2–5 个用户可理解的 research facets；
- 至少一个需要跨页比较、解释、协调或综合的输出；
- 允许用户自然知道的预算、时间、地点、已有设备和偏好；
- 不列出冻结页面中发现的价格、评分、规格冲突和证据结论；
- 不出现 scorer、proof step、seller assertion scope 等 benchmark 语言；
- 不把实验阈值、错误类型清单和推荐算法写进题面。

7.2 私有 Blueprint / Task Contract

私有资产保存：

- entities、constraints、facets、requested outputs；
- required source roles 及其认识论理由；
- answerability witnesses；
- conflict/unknown/bounded absence；
- disallowed inference；
- optional Decision Envelope；
- query round-trip 与 leak-lint 结果。

7.3 Query 泄漏检查

发布前自动比对 query 与 private case：

1. SKU、价格、评分、review count；
2. 冻结 assertion 的数字与单位；
3. conflict pair；
4. answerability witness 的独有术语；
5. evaluator rule 和 decision threshold；
6. 与其他 query 的高重合 n-gram / shingle。

用户已经提供的事实必须在 Blueprint 显式标为 user_provided；其他命中一律阻断。Query 中的 user_provided 事实不应再作为 evidence-bearing check 得分。

7.4 反模板与自然性

- 使用多组不同语气、结构和长度的 human-written development examples；
- renderer 只看 public Blueprint projection；
- 每个 attempt 保存完整请求、响应和失败历史；

- 独立 reviewer 只看 query，判断自然性、可答性和是否需要多分支研究；
- reviewer 还要从 query 反向恢复 facets，与 Blueprint 做 round-trip；
- 连续两次自然性盲审失败的题直接淘汰，不继续无限润色。

八、从候选题到正式题的 Release Gates

- **G0 World / Pack**: pack certificate、rights/PII、coverage、surface、hash；失败则 pack 不出题。
- **G1 Public/private hygiene**: 公开面无 gold、contract、oracle，并绑定快照；失败则 task 拒绝入库。
- **G2 Query quality**: 长度、leak lint、反模板、自然性、round-trip；失败可重试最多 2 次，之后淘汰。
- **G3 Answerability**: 每个 core facet 有 witness，并通过 source-role deletion 与 candidate saturation；失败则 revise scope 或淘汰。
- **G4 TWM quality**: assertions 可回原始 span，relations/conflicts/unknowns 与 query 一致；失败则修 compiler，不手工补分。
- **G5 RTS integrity**: 每个 unit 有 2-5 checks，并具备 evidence contracts、OR-of-AND 和依赖 DAG；失败则不得称可评分。
- **G6 Invariance**: 通过 oracle、null、fact dump、URL dump、deletion、valid alternate route 和 invalid route；失败则修 matcher/compiler。
- **G7 Human validity**: FRR/FAR、agreement、blind adjudication、PENDING=0；失败记为 ValidityGate fail。
- **G8 Capacity**: novel pairs、人时、队列峰值、裁决吞吐与安全系数过门；失败则缩小 formal，不降标准。
- **G9 Freeze**: 全部 manifest/hash、formal/reserve 分离、erratum/challenger 齐备；失败则不发布。

Formal task 必须有完整阶段目录和可重放 hash。状态字段不得由 task 文件自我声明。

九、六个月路线图

M1: 止损、正名与基础门

- 完成 E1 剩余人工审计；
- Truth56 冻结并正名；
- public/private artifact 分离；
- query leak linter 和 repo hygiene CI；
- 生成 Forum Coverage Census；
- 冻结 reviewer roster；
- 发布本 PDF v1。

停机条件：无法隔离 gold 或无法提供相互独立的人审角色时，正式题工作停止，只保留 dev/candidate。

M2: 现有世界 scale-up

- E2 W1M 过门并启动/恢复 Wfull；
- E3 Commerce/Community 全量重建；
- 从旧 100 个自然 query 中筛 scenario seed；
- 现有 56 题完成 query-only rewrite 候选，不改变旧 ID；
- 4 个任务走完真实 human pipeline。

停机条件：论坛/主题覆盖与旧 DATASHEET 严重不一致且无法解释时，不冻结 source-role 配额。

M3: Compiler 重建

- E2 Wfull candidate 与 E3 三方对齐；
- 从完整索引为 3 个任务建立 candidate pool saturation；
- TWM/RTS compiler 产生真实 relations、conflicts、unknowns、evidence contracts；
- 重放 audio_0002 并运行 V1-V10。

停机条件：oracle ceiling 失败、shortcut probe 获得高分、alternative route FRR 超门时，禁止批量扩题。

M4: 新垂直 MVP

- Science/Technical pack 通过 acquisition/rights/renderer pilot；
- Travel/Geo pack 通过 acquisition/rights/renderer pilot；
- 构建“3 个 vertical × 5 个 research shapes”的 15 题方法学 MVP；
- 完成 Dev-20；
- 运行 query round-trip、source-role deletion 和 granularity invariance。

停机条件：新 pack 不能证明至少一种现有环境测不到的 research unit 时，不进入正式 world。

M5: 候选题漏斗与交付合同

- Public Statistics pack pilot；
- intake 180 → answerability 140；
- 至少 110 题进入完整 pipeline；
- 完成 E5 search/browse/interaction bridge；
- 对 12 adapter 运行 delivery lineage canary；
- 在 Dev-20 上实测人时、novel pair、分歧率和队列峰值。

停机条件：CapacityGate 推算无法在冻结窗口前清零 PENDING 时，提前缩小 Formal 目标。

M6: 冻结与发布准备

- ValidityGate 与 CapacityGate；
- 冻结 Dev-20、Formal 最多 60、Reserve-16；
- 8-10 题反事实/canary 审计；
- cluster bootstrap、MDE 与等效并列层预注册；
- 发布 PDF v2、datasheet、environment card、validation report；
- V23-V30 与全部 formal entry 的 PENDING 未清零前不发榜。

十、人员、产能与成本

10.1 人工角色

至少需要：

- pack reviewer;
- source/evidence reviewer;
- graph/Blueprint annotator;
- independent adjudicator;
- blind query reviewer;
- matcher disagreement adjudicator;
- release manager。

同一任务的关键角色必须互斥。`actor_id` 不是身份证明，正式批次还需要冻结 reviewer roster 和实际账号映射。

10.2 人时规划

在 Dev-20 之前不承诺每题固定人时。初始规划假设为每个 full-pipeline candidate 3–5 人时，必须在 Dev-20 实测：

```
candidate-pool review
+ evidence review
+ Blueprint / annotation
+ query blind review
+ oracle / adversarial review
+ matcher adjudication
```

若 110 个 full-pipeline candidate 的实测负载超过团队带宽，应减少 Formal 数，而不是省略证据审核或让同一个模型/账号自审。

10.3 计算成本

环境与任务成本分开报告：

```
C_env = acquire + parse + index + render + audit
C_task = retrieve + semantic + compile + judge + adjudicate
```

每个新 pack 先跑稳定 1

十一、硬停机条件

发生任一条件时必须停止对应阶段：

1. 公开 query 或 task artifact 出现 private contract / gold;
2. query leak linter 命中未标记的冻结事实;
3. pack rights、PII 或 redistribution 状态不清楚;
4. E1/E2/E3 的 canonical artifact 无法回到 agent-visible 页面;
5. query 要求 community evidence, 但 forum coverage 不能证明;
6. query 声称冲突或 bounded absence, TWM 却无对应结构;
7. RTS 退化为一段长 prose check;
8. oracle 不能满分, null/URL dump/fact dump 获得实质高分;
9. 合法替代路线被拒或非法相似路线大量通过;

10. blind reviewer、annotator 与 adjudicator 不是独立角色；
11. PENDING 无法在冻结前清零；
12. CapacityGate 预测正式集无法在预算内完成；
13. 任何团队成员试图根据 12 个被评 harness 的排名反向修改正式题。

十二、明确不做

- 不在当前 transition builder 上继续批量追加题目；
- 不把 query 写得更长来“提高严谨性”；
- 不强制每题三源齐全；
- 不把 forum、vertical 和 source role 混为同一维度；
- 不在正式 task 文件中保存 generator_view、candidate actions 或 evaluator view；
- 不让 LLM renderer 自己批准 query；
- 不让单一 operator 账号同时充当 author、annotator、adjudicator 和 blind reviewer；
- 不因某 harness 得分低而降低 check 或改变 applicability；
- 不用页面数量代表研究难度；
- 不把 new pack 的 hidden construction oracle 当作 agent evidence；
- 不在旧 manifest 上静默重算；
- 不在 ReleaseGate 通过前发布排行榜。

十三、交付物清单

环境

- environment-card-vNext.md/pdf
- domain-pack-manifests/
- coverage-certificates/
- rights-pii-decisions/
- world-index-manifest.json
- delivery-bridge-manifest.json
- forum-coverage-census.json/md

Query 与任务

- query-portfolio-manifest.json
- scenario-intake/
- case-blueprints/
- query-pipeline/<candidate_id>/
- task-world-models/
- research-test-suites/
- answerability-certificates/
- query-leak-lint-report.json
- duplicate-cluster-report.json

验证与发布

- dev20-validation-report.md/pdf
- validity-gate.json
- capacity-gate.json
- formal60-manifest.json
- reserve16-manifest.json
- counterfactual-canary-report.md/pdf
- benchmark-datasheet.md/pdf

十四、成功标准

首版成功不是“题目超过 56”或“环境达到若干百万页面”。成功必须同时满足：

1. 每个 formal query 自然、短、无答案事实和评分边界泄漏；
2. 每个 core facet 有可达 witness，但运行时不绑定 witness URL；
3. TWM 来自完整世界的 query-conditioned candidate pool；
4. RTS 的每个 check 有可执行 content/evidence contract；
5. 新合法证据可以通过，困难非法证据被拒；
6. 所有得分可回到 report span、delivered evidence 和 source role；
7. Dev-20 上的 scorer-human 校准、FRR/FAR 和产能过门；
8. Formal 与 Reserve 都有完整可重放治理资产；
9. 统计报告使用 cluster bootstrap 和等效并列层，不强行制造全序；
10. 旧 Truth56、旧榜和新 vNext manifest 可以并排重放，互不覆盖。

十五、状态命名

- **legacy_historical**：可以声称“可重放的旧结果”；不可以声称“新协议有效”。
- **diagnostic_transition**：可以声称“工程诊断资产”；不可以声称 formal、gold 或可发榜。
- **structurally_compiled_candidate**：可以声称 schema/graph 已编译；不可以声称人工治理或 answerability 已完成。
- **human_governed_candidate**：可以声称 query/evidence/annotation 链可重放；不可以声称 scorer 已校准。
- **release_gate_candidate**：可以声称 oracle、对抗与 validity/capacity 正在验收；不可以声称已冻结。
- **released_formal_task**：可以声称已进入固定正式分母；不可以被单方静默修改。

内部参考

设计与流程：Sandbox-native Scoring Design (2026-07-17)、Human Query Generation Workflow (2026-07-16)、Evidence Graph Redesign Plan (2026-07-15)、Route-flexible Rubric Migration (2026-07-17)。

运行与资产：E1 Shard Compiler Runbook、E2 Wikimedia Backbone Runbook、DATASHEET、pilot v3.3 audio 0002、Truth56 20260727 assets。