

Deep Research Arena

可复现实验手册：从零到 Truth 榜
完整流程、命令、产物、验收与已知限制

与仓库代码口径对齐（含 docs/RUNNING_EXPERIMENTS.md）
日期：2026-07-09
分支参考：fix/pof-citation-extractor

Abstract

本手册面向需要亲手复现 Deep Research Arena（DRA）评测的人。按章节顺序执行，应能：拉起沙箱 → 通过预检 → 跑 lane → 拿到证据日志与报告 → 建成带版本戳的 truth 榜。凡是仪器尚未强制的地方，文中用「现状」标明，避免把设计目标当成已落地能力。

Contents

1 本手册能让你复现什么	3
2 仓库与工作目录	3
3 评分在测什么（复现前先对齐概念）	3
3.1 封闭世界	3
3.2 Truth 公式（生产 K6）	3
3.3 各量回答的问题	4
3.4 仪器拒绝做什么	4
4 第 1 步：拉起沙箱	4
4.1 Docker 内容面	4
4.2 Shim 与 ds_proxy（评测必开）	4
4.3 并行 worker	4
5 第 2 步：预检（不过不许开跑）	5
6 第 3 步：任务与答案键	5
6.1 任务	5
6.2 答案键	5
7 第 4 步：公平性合同（加 lane 必读）	5
8 第 5 步：跑一次任务	5
8.1 每次 run 的产物	6
8.2 预算与 stalled	6
9 第 6 步：页面缓存（打分只读缓存，不现场上网）	6
10 第 7 步：建 Truth 榜	6
10.1 核对你复现的是不是同一口径	6
11 第 8 步：Usefulness Jury（可选，与 truth 正交）	7
12 端到端最小复现清单（建议打印勾选）	7
13 现状缺口（复现时必须知情）	7
13.1 网络层尚未强制「只能经 shim 读页」	7
13.2 其他限制	7

14 公式与门的设计意图（便于写进实验记录）	8
15 故障排查速查	8
16 命令总表	8
17 结语	8

1 本手册能让你复现什么

- 封闭沙箱上的一次（或多 lane）Deep Research 跑批
- 可判定 truth 分： $\text{truth} = \text{reach}^{1.5} \cdot (0.39 \text{ fact} + 0.28 \text{ pof} + 0.33 \text{ completeness})$
- 带 board.protocols 版本戳的 JSON 榜，可与他人板子比对是否同口径

本手册不保证：开放网页评测、历史无证据日志档案的 transport PoF 重打、以及「所有 12 条 lane 都有硬 PoF」。后者取决于网络层是否已把沙箱端口只暴露给 shim（见第 13 节）。

2 仓库与工作目录

```
# 假设仓库在：
cd /path/to/deep_research # 本机常见路径：/root/Desktop/lyb/deep_research
export PYTHONPATH=.
git rev-parse HEAD
git status --short
```

关键目录：

路径	用途
infra/sandbox.docker-compose.yml	沙箱编排
integrations/search_shim/	搜索/取页 shim（观测入口）
integrations/ds_proxy/	LLM 代理与 token 记账
config/lane_protocol.yaml	公平性与 fetch 可观测声明
data/tasks/deep_research/	任务 intent
data/golden/answer_keys/	打分用答案键
scripts/run_deep_task.py	单次跑入口
scripts/preflight.py	开跑前硬门禁
scripts/build_truth_board.py	建 truth 榜
src/eval/decidable_scorer.py	K6 打分实现
src/eval/fetch_log.py	transport 证据定义
logs/fetch/	每 run 的搜/读证据

3 评分在测什么（复现前先对齐概念）

3.1 封闭世界

Agent 应只接触：

- Magento 购物站 :7770
- Postmill 论坛 :9999
- Kiwix Wikipedia :8090

经 search shim（默认 :8081）搜索与取页。没有「当天公网」作为真值来源。

3.2 Truth 公式（生产 K6）

$$\text{quality} = 0.39 \cdot \text{fact} + 0.28 \cdot \text{pof} + 0.33 \cdot \text{completeness}$$

$$\text{truth} = \text{reach}^{\gamma} \cdot \text{quality}, \quad \gamma = 1.5$$

- spec（格式）只进 compliance 列，**不乘进** truth
- 无 quality 地板（EPS_FLOOR=0.0）
- 权重为声明约定，不宣称最优；原始轴分应随板公开

3.3 各量回答的问题

量	问题
reach	引用的 URL 是否在冻结语料中 / 可达?
pof (transport_v2)	agent 是否打开过 它引用的页? (看 shim 证据日志)
snippet_only	引了真页但没打开, 搜索却返回过该 URL+ 摘要
hallucinated_grounding	引了真页, 但既没打开也没搜到 (偏参数记忆)
fabrication	URL 根本不在语料里
quote_support / 旧 text_v1	写的内容是否像页面 (文本下界; 不是 取回证明)
fact	结构化声明是否与 DB/answer key 一致
completeness	vital 要点覆盖了多少

3.4 仪器拒绝做什么

若某 run 无证据日志, 或该 lane 读页绕过 shim:

- 默认 `--require-transport-pof`: 该 lane **不上板** (withhold), 并打印原因
- 显式 `--no-require-transport-pof`: 回退 text_v1, 板子戳 pof_semantics: text_v1, 与 transport 板不可比
- **绝不**把「没观测到」打成 pof=0 (那是诬告)

4 第 1 步: 拉起沙箱

4.1 Docker 内容面

```
docker compose -f infra/sandbox.docker-compose.yml up -d

curl -fsS http://localhost:8081/healthz # 若 compose 已含 gateway
curl -fsS http://localhost:7770/
curl -fsS http://localhost:9999/
curl -fsS http://localhost:8090/
```

Wiki 需准备 .zim 并设置 WIKI_ZIM_DIR (见 infra/build-images.md)。购物/论坛镜像拉不下时走离线重建 Path C。

4.2 Shim 与 ds_proxy (评测必开)

即使 compose 已有 gateway, 实验文档要求明确拉起可记账服务:

```
# 搜索/取页 shim: agent 接触沙箱的正门
uvicorn integrations.search_shim.app:app --host 0.0.0.0 --port 8081

# LLM 代理: 统一底模 + token 归因
mkdir -p logs
DSPROXY_USAGE_LOG=logs/usage.jsonl \
  uvicorn integrations.ds_proxy.app:app --host 0.0.0.0 --port 8088
```

环境变量示例:

```
export SHOPPING=http://localhost:7770 # 或 17770, 与任务占位符一致
export REDDIT=http://localhost:9999
export WIKIPEDIA=http://localhost:8090
export TAVILY_API_URL=http://localhost:8081
export DS_PROXY_URL=http://localhost:8088/v1
export OPENAI_BASE_URL=$DS_PROXY_URL
export OPENAI_API_KEY=anything-proxy-uses-server-key
# 底模密钥按你的上游填写 (vLLM / DashScope 等)
```

4.3 并行 worker

一个 shim 同时只服务一个打开的 /_mark 括号; 第二路会 409。并行时每 worker 一个 shim 端口 (由 DRA_WORKER_ID 派生; 见 run_full_leaderboard.sh)。

5 第 2 步：预检（不过不许开跑）

```
python3 scripts/preflight.py --all
```

非零退出码 = 不要跑。核心包括：

- **Canary**：假 agent 搜两次、打开一页、引用三个 URL（含未打开真页与不存在 URL），仪器必须能分开
- `scripts/check_parity.py`：adapter 是否偷偷塞引用数/字数/示例 URL 等
- 箱上专属检查若无法跑会标 SKIP（不得静默 PASS）

历史教训：子集 312 个 run 的 `shim_search_delta` 全为 0 却无人报警——「从没搜过」与「从记到搜过」在数据上不可分。预检就是为防这件事再发生。

6 第 3 步：任务与答案键

6.1 任务

```
ls data/tasks/deep_research/cross_site_deep/ | head
# 例: dr_cross_deep_0001.json 字段含 intent, sites, markdown_spec, ...
```

Agent 主要消费 `intent`（其中 `__SHOPPING__` 等占位符会被替换成沙箱 URL）。不要把 `must-cite` 列表喂给 agent。

6.2 答案键

```
ls data/golden/answer_keys/ | head
python3 - <<'PY'
import json
from pathlib import Path
p=Path("data/golden/answer_keys/dr_cross_deep_0001.json")
d=json.loads(p.read_text())
print(d.keys())
print("vital", len(d.get("vital_nuggets", [])),
      "relevant", len(d.get("relevant_set", [])))
PY
```

字段要点：`relevant_set`、`vital_nuggets`、`useful_nuggets`、`spec_requirements`。跨站 `gold_contradictions` 多数为空——不进 K6 truth，复现时不要依赖它。

可打分任务集合以 `data/golden/deep_clean/_manifest.json` 为准（约 75 scorable）。

7 第 4 步：公平性合同（加 lane 必读）

合同文件：`config/lane_protocol.yaml`。

每条 lane 只应得到：共享 `intent` + 一句「交一份自洽 Markdown 报告」。禁止：

- 引用数量、字数/段落数、搜索次数、引用格式处方、示例 URL
- harness 往终稿嫁接 URL / Sources 块
- 按得分轴自动 `retry/repair`
- 把模型写出的公网 wiki 改写成沙箱 URL（掩盖漂移）

实测过的违规代价（摘要）：`ldr` 嫁接 Sources 后 `macro reach` 从 ~ 0.95 降到 0（去掉嫁接后）；`smolagents` 曾按 `localhost` URL 数自动重试等。详见 `docs/RUNNING_EXPERIMENTS.md § 4`。

新 lane 必须在 `yaml` 声明 `delivery / fetch_mode / fetch_observable`。`fetch_observable: true` 前必须在箱上看到该 run 的 `logs/fetch/<run_id>.jsonl` 含 `fetch` 行。

8 第 5 步：跑一次任务

```
python3 scripts/run_deep_task.py \
  --agent deerflow \
  --task dr_cross_deep_0001 \
  --backbone qwen3-8b \
  --out-suffix repro1
```

--agent 必须是 RUNNERS 已注册名（见脚本 choices=）。

Harness 应：生成 run_id；对 shim 与 ds_proxy 开 /_mark；finally 关闭。Shim 不可达应响亮失败，而不是无仪器继续跑。

8.1 每次 run 的产物

文件	证明什么
<agent>/<task>.md 或约定命名报告	框架自己的输出字节
*.meta.json	状态、耗时、报告 sha256 封印
logs/fetch/<run_id>.jsonl	本次经 shim 的 search/fetch
logs/fetch/blobs/<sha256>	agent 当时看到的页面字节
logs/usage.jsonl	token，按 run_id 归因

打分时会校验封印：跑完后若有人追加 Sources/参考文献，会报 TAMPERED。

8.2 预算与 stalled

- 没有比较用的墙钟限额；成本比 token
- 无进展看门狗：连续 stall_timeout_s（默认 900s）既无 LLM 调用也无 shim 调用 ⇒ 记 stalled（基建故障，可重跑）
- 仅「重跑额度用尽仍 stalled」才计 0；若仍有欠重跑的 stalled，build_truth_board 拒绝出板

9 第 6 步：页面缓存（打分只读缓存，不现场上网）

```
# 按报告中出现的 URL 预热缓存（在可访问沙箱的机器上）
python3 scripts/build_sandbox_cache.py --workers 6 --timeout 5
# 具体参数以脚本 --help 为准；输出 sandbox_cache.json
```

打分时 cache miss 抛错，不再现场 HTTP 补抓（避免用评测方请求「证实」模型猜中的 URL）。

10 第 7 步：建 Truth 榜

```
python3 scripts/build_truth_board.py \
  --reports-dir data/results/deep/<backbone> \
  --keys-dir data/golden/answer_keys \
  --evidence-dir logs/fetch \
  --cache sandbox_cache.json \
  --out board.json
```

默认行为（以当前脚本为准）：

- --require-transport-pof 默认 开：无 transport 证据的 lane withhold
 - --missing-as-zero 默认 开：缺报告的题计 0（避免「只跑成功的题」幸存者偏差）
 - --min-coverage 默认 0.5：覆盖不足标 low_coverage，不进 headline 宣称
 - 同一板禁止混用 text_v1 与 transport_v2（退出码 3）
 - 没有任何 lane 可打分则拒绝写空板（退出码 5）
- 可选：--panel winrates.json 仅用于近乎打平时的 presentation 破平局，不进入 truth 数值。

10.1 核对你复现的是不是同一口径

```
python3 - <<'PY'
import json
p=json.load(open("board.json"))
print(p.get("protocols"))
PY
```

比对: formula_version、extractor_commit、pof_semantics、task_set_hash、gamma、weights。任一不同, 数字不可比。

更完整的主机级指纹: scripts/run_manifest.py (git commit、脏树、影响分数的文件哈希、venv、语料指纹、模型身份探针)。在不同主机生成的 manifest, verify() 会拒绝。

11 第 8 步: Usefulness Jury (可选, 与 truth 正交)

```
# 见 scripts/run_usefulness_jury.py --help
# 产出 battles.jsonl -> Bradley-Terry 胜率/Elo
```

- 判官评「对人是否有用」, 不评引用真假
- 与 truth 的 Spearman 可为负: 两轴测不同构念; 不要用 jury 裁决哪个 truth 对
- 历史 live 框架榜约 40.5% 单判官: 复现对外数字前先查 jury 源是否三判官齐全

12 端到端最小复现清单 (建议打印勾选)

```
docker compose ... up -d; 7770/9999/8090 可 curl
shim:8081、ds_proxy:8088 在跑; DSPROXY_USAGE_LOG 已设
PYTHONPATH=.; preflight.py --all 退出 0
check_parity.py 无 violation
选定 --agent/--task/--backbone; 跑通 run_deep_task.py
存在报告 md + meta (含 sha256)
存在 logs/fetch/<run_id>.jsonl; 若声称可读页则有 fetch 行
准备 sandbox_cache.json
build_truth_board.py 成功; 检查 protocols
记录 git HEAD、是否脏树、公式版本, 写入实验笔记
```

13 现状缺口 (复现时必须知情)

13.1 网络层尚未强制「只能经 shim 读页」

进程内 gate 目前主要拦站外, 且对 localhost:7770 等仍可能直连; 且只补丁部分 HTTP 客户端。aiohttp/httpx/curl 可绕过。

因此今日 (协议声明口径):

fetch_observable	典型 lane 与 pof
true	flowsearcher-ds、camel-ai (经 /extract)、storm / langchain-odr (无读页, snippet_only) ⇒ 可 transport
false	smolagents、gpt-researcher、deerflow、ii、qx、claude-code、opencode、ldr ⇒ 默认 withhold

根治: 沙箱端口仅 shim 可达 (网络命名空间/防火墙), 则任意客户端不经 shim 就会失败, fetch_observable 由构造为真。在此之前, 默认 withhold 是刻意的强制函数, 不是疏忽。

13.2 其他限制

1. 模型身份探针读的是 endpoint 自报; 不能证明权重文件
2. 长驻服务未必随磁盘代码热更新; /healthz 暴露已加载模块 sha 尚未实现
3. quote_support 是逐字下界, 释义会漏
4. 跨底模 thinking 等未 runtime 强制齐平前, 只能当 lane 比较, 不能当纯 backbone 消融
5. 历史无证据日志的档案无法用 transport_v2 重打 PoF
6. 并发归因靠「一 shim 一括号」, 请求本身不带 run_id header

14 公式与门的设计意图（便于写进实验记录）

- C1: reach= 0 的纯编造 truth 必须为 0（乘法门）
 - C2: 零实质空壳（即便格式满分）truth 必须为 0（spec 移出 + 无地板）
 - PoF 目标语义是取回证据；text_v1 仅是显式降级且不可与 transport 板混比
 - Presentation/jury 与 truth 分离；合成若做乘法优先用 BT 胜率而非 Elo
- 相关维护者文档(若本地有 internal/): FORMULA_LOCK_*.md、FETCH_PATH_AUDIT_*.md、ROOT_CAUSE_*.md。

15 故障排查速查

现象	先查
preflight 失败 跑起来但无 logs/fetch/<run_id>.jsonl 板子 withhold 某 lane	canary 日志；shim 是否在记 search/fetch；parity 命中行 是否对 shim 发了 /_mark（不是只对 ds_proxy） 该 lane fetch_observable；jsonl 有无 fetch；是否 -no-require-transport-pof
cache miss 报错 分数与论文表对不上 stalled 很多	先 build_sandbox_cache；确认 URL 规范化一致 比对 protocols；是否旧 gated-Elo 板 vs K6 truth 板 vLLM/代理健康；900s 无进展定义；先重跑再计 0

16 命令总表

```
export PYTHONPATH=.

# 预检
python3 scripts/preflight.py --all
python3 scripts/check_parity.py

# 单跑
python3 scripts/run_deep_task.py \
  --agent <lane> --task <task_id> --backbone <model>

# 缓存
python3 scripts/build_sandbox_cache.py --help

# 出板
python3 scripts/build_truth_board.py \
  --reports-dir <dir> \
  --keys-dir data/golden/answer_keys \
  --evidence-dir logs/fetch \
  --cache sandbox_cache.json \
  --out board.json

# 显式降级（会戳 text_v1，勿与 transport 板比较）
python3 scripts/build_truth_board.py ... --no-require-transport-pof

# 口径
python3 -c "import json;print(json.load(open('board.json'))['protocols'])"
```

17 结语

可复现的最小闭环是：

冻结沙箱 + 预检通过 + 带 /_mark 的跑次 + 证据日志 + 只读缓存打分 + 带 protocols 的 truth 板。

在网络层强制「读页必经 shim」之前，请把 withhold 的 lane 当作**尚未可硬测 PoF**，而不是当作 PoF= 0 的差生。对外报告数字时，始终附上 formula_version 与 pof_semantics。

文档日期 2026-07-09。若与后续 commit 冲突，以脚本默认参数、lane_protocol.yaml 与 board.protocols 为准。英文操作摘要见 docs/RUNNING_EXPERIMENTS.md。