

DRA 报告级四轴真实性评分重构

Task Evidence Census

Claim Fact · Observed Evidence · Corpus Completeness · Rubric Fulfillment

保留 $Truth = Provenance \times Quality$, 重做内层四个构念

目录

DRA 报告级四轴真实性评分重构	2
Rubric Fulfillment、Claim Fact、Observed Evidence 与 Corpus Completeness	2
0. 一页结论	2
1. 我们要保住的东西	3
2. 为什么旧三项现在不够	3
2.1 旧 Fact 不是报告事实正确性	3
2.2 旧 ProofOfFetch 混了两个概念	3
2.3 旧 Completeness 容易变成“复现预选页面”	4
2.4 用户要求不能被“语料覆盖率”替代	4
2.5 旧权重没有错在小数点，而是语义未分开	4
3. 文献给出的共同结构	4
4. 总体架构	5
4.1 构建期：昂贵但只做一次	5
4.2 运行期：所有 harness 完全相同	6
5. 冻结语料与 Task Evidence Census	6
5.1 输入是冻结语料，不是新的全局前置工程	6
5.2 每题提前生成的 TEC 资产	7
5.3 相关页面与命题闭包如何尽量做全	7
5.4 公平性边界	9
5.5 “完整”的诚实定义	9
6. TEC 中的三类冻结单元	9
6.1 Atomic fact units	9
6.2 Higher-order research units	10
6.3 Explicit 与 latent rubric items	11
7. Fact: NLI 采集、独立检索与多状态裁决	11
7.1 Claim 采集不是一次自由生成	11
7.2 报告 claim schema	13
7.3 哪些 claim 进入 Fact	13
7.4 Fact Agent 必须独立于报告引用	15
7.5 Fact 的多状态裁决	15
7.6 冻结世界外不惩罚	16
7.7 Fact 公式	16
7.8 表外 claim 或 URL 的版本治理	17

8. Evidence: 接替旧 ProofOfFetch 槽	17
8.1 为什么不能只按 URL 计	17
8.2 Citation binding	17
8.3 一个 binding 何时通过	18
8.4 Evidence Agent: NLI 初筛、DeepSeek-V4-Lite 复核与人工抽查	18
8.5 整页与 snippet 的统一规则	18
8.6 Evidence 公式	19
8.7 原始 PoF 留在哪里	19
9. Completeness: 相对可发现内容集合的覆盖率	19
9.1 Completeness 不再与 Fact 重复	19
9.2 Atomic 与 research unit coverage	20
9.3 分层宏平均	20
9.4 “最大子集”的可审计含义	20
9.5 深度如何进入 Completeness	21
10. Rubric Fulfillment: 用户要求与潜在研究要求	21
10.1 两类 rubric	21
10.2 Rubric item 的通过条件	21
10.3 Rubric 公式	21
10.4 防止 latent rubric 变成隐藏答案	22
11. Provenance: 只测 URL 是否真实存在	22
11.1 定义	22
11.2 发现与抓取过程单独审计	22
11.3 为什么与 Evidence 不相同	23
12. 最终合成与权重	23
12.1 候选正式公式	23
12.2 为什么先等权	24
12.3 Legacy ablation	24
12.4 缺失轴不重归一化	24
12.5 跨任务聚合	24
13. 写作 Elo 单独报告	25
14. 失败类型的唯一责任表	25
15. 极端案例推演	27
15.1 空报告或纯格式空壳	27
15.2 一条完全正确且有证据的短答案	27
15.3 宽泛事实堆砌, 没有比较和结论	27

15.4 逻辑漂亮但靠参数知识，没有本次引用	27
15.5 抓了许多页面但引用全错	27
15.6 Snippet-only harness 完成浅事实核对	27
15.7 使用不同于构题路线的真实页面	28
15.8 一个伪造 URL 混在十个真实 URL 中	28
15.9 报告内容优秀但文风很差	28
15.10 运行日志坏了	28
15.11 引用页面支持说法，但世界证据反驳	28
16. Census gap 与版本治理	28
16.1 为什么不能把 on-demand 当正常功能	28
16.2 挑战流程	29
16.3 防止恶意 DoS	29
17. 校准与验证计划	29
17.1 TEC corpus scan 召回	29
17.2 Claim extractor	30
17.3 Fact 与 Evidence judge	30
17.4 Rubric judge	31
17.5 运行账本注入测试	31
17.6 端到端不变量	32
17.7 权重敏感性	32
18. 一道任务的示意产物	32
19. 实施路线	33
Phase 0: 公式与 schema 锁定	33
Phase 1: 单题完整 TEC	33
Phase 2: 真实 harness pilot	34
Phase 3: Dev-14	34
Phase 4: 56 题扩展	34
Phase 5: 榜单与论文	34
20. 可能的 reviewer challenge 与回答	35
Challenge 1: TEC 仍然是 LLM 生成的 rubric	35
Challenge 2: 你们真的枚举了全部相关事实和 URL 吗	35
Challenge 3: evaluator 的向量库比 agent 强，不公平	35
Challenge 4: Fact 与 Completeness 都是 recall	35
Challenge 5: Evidence 与 Provenance 都在罚引用	35
Challenge 6: 为什么用加权，为什么等权	35

Challenge 7: 零 citation 但内容全对为什么 Truth 为零	36
Challenge 8: 为什么不用一个额外 Depth 主轴	36
Challenge 9: 表外 claim 会让榜单频繁重算	36
Challenge 10: 为什么相信 NLI 与 DeepSeek-V4-Lite	36
Challenge 11: latent rubric 会不会成为隐藏答案	36
21. 需要立即拍板的规格	36
22. 最终判词	37
参考资料	37

DRA 报告级四轴真实性评分重构

Rubric Fulfillment、Claim Fact、Observed Evidence 与 Corpus Completeness

版本：Draft v1.2, 2026-07-24 文档性质：独立的新方案，不覆盖 DRA_SANDBOX_NATIVE_SCORING_DESIGN_2026-07-17.md。目标：保留报告级 Truth = Provenance × Quality 的直觉与自动化优势，同时修正旧 Fact / ProofOfFetch / Completeness 的构念错位、重复计分和任务路线绑定，并显式加入用户要求与预先冻结的潜在研究要求。

0. 一页结论

保留报告级骨架：

$$\begin{aligned} \text{Quality}_t &= w_F \text{Fact}_t + w_E \text{Evidence}_t \\ &\quad + w_C \text{Completeness}_t + w_R \text{Rubric}_t, \\ \text{Truth}_t &= \text{Provenance}_t \cdot \text{Quality}_t, \\ w_F + w_E + w_C + w_R &= 1. \end{aligned}$$

但四个内层项必须互不替代地回答不同问题：

新轴	回答的问题	分母	主判定资产
Fact	报告主动说出的、可裁决原子事实有多准确？	报告中可裁决的 material atomic claims	独立多来源事实证据包 + Fact judge
Evidence	报告中的外部主张有多少真正绑定了本次观察到、且确实支持它的证据？	citation bindings；报告中 citation-required units	运行账本 + 冻结 evidence spans
Completeness	相对该题可发现、可回答的内容集合，报告覆盖了多少原子事实与高阶研究单元？	TEC 中 protocol-complete 的 atomic + higher-order units	多路全库检索 + Task Evidence Census
Rubric	报告是否满足用户明确要求，以及在看答案前冻结的潜在研究要求？	explicit + latent rubric items	Task Contract + 双人审核 rubric
Provenance	报告引用的 URL 是否真实存在、可规范化并有冻结内容快照？	报告中的唯一 evidence URLs	URL registry + HTTP/快照记录

写作流畅度、结构和可读性采用独立 pairwise jury / Bradley–Terry Elo；它不乘入 Truth，也不改变真实性排名。

旧权重 0.39 / 0.28 / 0.33 仅保留为 legacy ablation。新定义改变了构念，并增加了 Rubric，不能继承旧权重的含义。首个候选版本采用四轴等权：

$$w_F = w_E = w_C = w_R = \frac{1}{4}.$$

等权不是声称四种错误伤害完全相同，而是在没有可靠效用函数时避免伪精确；正式版本必须同时发布四个 raw axes、门槛/几何聚合 ablation 与权重敏感性结果。

本方案最关键的构建变化是：**每道题发布前先完成一次 Task Evidence Census（TEC，单题证据普查）**，对冻结世界做全库候选扫描，并把所有计分分母、任务相关事实/关系单元、支持与反驳 span、等价 URL、排除记录和可发现性证书冻结。正式评分只对这份版本化总账做匹配，不临时改变答案空间。

如果正式运行发现了一个表外、真实、任务相关且会影响得分的 claim，或者发现一个未登记但确实支持既有单元的新 URL，这都不是正常的“按需加分”，而是 `census_gap`：该版本的题目暂停进入正式榜，修复 TEC、提升版本，并对所有历史报告统一重算。任何单份报告都不能因为先暴露了漏项而获得一条私有评分路线。

1. 我们要保住的东西

旧方案并不是一项差工作。它有四个非常重要、应当保留的优点：

1. 自动化程度高；
2. 冻结输入下结果可复现；
3. 不依赖运行后临时编写、针对某份报告的大型人工 rubric；
4. 所有 harness 使用完全相同的程序、registry、页面快照和评分器。

因此，新方案不是把确定性评测推翻为一个大型 LLM rubric judge。它仍以冻结世界、固定表、可回放账本 and 可审计 span 为主；LLM 只承担四个边界清楚、可校准的窄任务：

- 从报告原文中提出原子 claim 候选；
- 使用 NLI 与独立 verifier 检查 claim 是否被原文蕴含、是否保持限定条件；
- 在给定冻结候选 span 后判定支持、反驳、冲突或不可裁决；
- 匹配报告内容与预先冻结的 rubric / completeness units。

LLM 不被允许自由上网，不被允许凭参数知识补事实，也不被允许自行改变计分分母。

2. 为什么旧三项现在不够

2.1 旧 Fact 不是报告事实正确性

当前 `score_fact_support` 主要检查与商城实体绑定的价格和 overall rating，并在内部计算 volume-aware F1。代码和 README 已经明确记录：在一组 140 份报告中，只有 2 份出现可检查 claim，约百分之 98.6 的报告中 Fact 失活。

因此，名义权重 0.39 并不代表百分之 39 的真实区分力。更严重的是，它只衡量购物数据库中的两个字段，却被命名为整个报告的 Fact。

结论：保留现有结构化字段验证器，但把 Fact 扩展为覆盖整个报告的 claim-level factuality。

2.2 旧 ProofOfFetch 混了两个构念

当前存在两种不同语义：

- `transport_v2`: $|cited \cap fetched_{200}| / |cited|$ ，能证明某 URL 本次被成功抓取；
- `text_v1`：评测器事后页面缓存与报告引用附近文本的逐字匹配，只能说明存在 lexical overlap，不能证明 agent 本次抓取过页面。

前者是过程事实，后者更接近 quote fidelity。二者不应共享一个名为 ProofOfFetch 的质量槽位。

更重要的是，“抓过页面”本身不是报告质量。一个 agent 可以抓取一百个页面、最终完全不用它们。真正应进入报告质量的是：**报告里的主张是否绑定了本次实际观察、且能支持该主张的证据。**

结论：原始 URL-level FetchRate 退出主分、保留为诊断；旧 PoF 槽由 Evidence 接替。

2.3 旧 Completeness 容易变成“复现预选页面”

当前 vital pool 每题通常约 14–17 条，小于 $K^*=20$ ，实际接近对答案键的全量普查。若 vital nuggets 来自构题时预选页面，并要求同一 source_url，就会把出题路线变成 agent 必须复现的路线。

这无法完整测量 Deep Research：一个好报告不仅要提到若干事实，还要完成比较、机制解释、冲突处理、社区经验综合、教程、预算方案和最终决策。

结论：Completeness 的分母必须从 query 与冻结世界共同编译，覆盖可发现的 atomic facts 与 higher-order research units；它不再统计预选 URL，也不再把 coverage 塞进 Fact。

2.4 用户要求不能被“语料覆盖率”替代

一个报告可以覆盖大量事实，却没有回答用户真正的问题。例如，用户要求“在固定预算下比较两个方案并给出最终选择”，报告即使列出很多规格，只要没有预算约束、比较和推荐，就没有完成任务。

因此新增 Rubric Fulfillment：

- explicit rubric 直接来自 query 中明确写出的约束、候选、输出形式和决策要求；
- latent rubric 是完成该类研究不可缺少、但 query 未逐字写出的要求，例如处理来源冲突、区分厂商声明与用户体验、说明关键不确定性；
- 所有 latent rubric 必须在看到任何 harness 报告前生成、双人审核并冻结；
- rubric 不能把某个参考答案的具体结论或特定 URL 写成必须复现的路线。

2.5 旧权重没有错在小数点，而是语义未分开

0.39 / 0.28 / 0.33 是声明式 harm ordering 的归一化结果，不是从人类偏好、预测效率或统计拟合中得到。只要三项还存在失活、重叠和命名错位，继续调小数无法解决构念问题。

先修轴，再讨论权重。

3. 文献给出的共同结构

现有 Deep Research benchmark 很少只看一个答案是否正确。反复出现的构念可以归为四组：

构念家族	代表工作	对本方案的启发
内容正确性与引用准确性	FActScore、ALCE、DeepResearch Bench FACT	把长文本拆成 claims；事实真假与引用是否支持要分开
覆盖与信息召回	DeepResearch Bench I/II、ResearcherBench	深搜报告需要显式测 breadth，而不是只测少量事实
分析、综合与任务完成	DeepResearch Bench I/II、LiveResearchBench、DEER	比较、机制、冲突、综合和决策必须进入正式测量对象

构念家族	代表工作	对本方案的启发
呈现与可读性	DeepResearch Bench I/II、 DeepResearchGym、LiveResearchBench	写作质量有价值，但不应污染可判定真实性分

FActScore¹ 将长文本拆成 atomic facts 并计算被知识源支持的比例；它证明 claim-level 检查可以规模化，也提醒我们 atomicity 和去重决定指标是否可用。

DeepResearch Bench² 把报告的 comprehensiveness、insight/depth、instruction-following、readability 与 FACT 引用验证分开；DeepResearch Bench II³ 则使用 information recall、analysis、presentation 三类细粒度标准。

ResearcherBench⁴ 同时报告 rubric insight、faithfulness 与 groundedness，而不是把“引用支持”和“信息覆盖”混成一个量。LiveResearchBench⁵ 也把 coverage、presentation、consistency、analysis depth、citation association 与 citation accuracy 分开。

DRA 的差异不是再复制这些 rubric，而是利用冻结沙盒把它们改造成：**预编译的任务事实/关系普查 + 运行时可回放的观察证据**。

4. 总体架构




图 1: DRA 四轴评分：构建期冻结 Task Evidence Census 与 Rubric Manifest，运行期只匹配报告、冻结证据和本次观察账本。

系统严格分为两个阶段。

4.1 构建期：昂贵但只做一次

Frozen World

¹<https://arxiv.org/abs/2305.14251>

²<https://arxiv.org/abs/2506.11763>

³<https://arxiv.org/abs/2601.08536>

⁴<https://arxiv.org/abs/2507.16280>

⁵<https://arxiv.org/abs/2510.14240>

- per-task multi-channel corpus scan
- task-relevant page closure
- semantic extraction and canonicalization
- Task Evidence Census
- coverage/discoverability certificate
- frozen task scoring manifest

构建期 evaluator 可以使用全量 BM25、精确/近似向量检索、结构化字段查询、链接图扩展和 LLM 语义抽取。它拥有比被测 harness 更强的“全知外挂”，因为它承担的是建立测试标准，而不是与 agent 竞争搜索。

4.2 运行期：所有 harness 完全相同

- Agent report + run ledger
- extract report claims / relations / citation bindings
 - table match against the frozen task manifest
 - Fact, Evidence, Completeness, Rubric, Provenance
 - Truth
 - writing jury/Elo reported separately

正式评分器不得临时重新抓取互联网，不得让 judge 使用自身知识补证据，也不得根据某个 harness 的输出改变分母。

5. 冻结语料与 Task Evidence Census




图 2: 单题 Task Evidence Census 的编译、准入与 census-gap 修复闭环。

5.1 输入是冻结语料，不是新的全局前置工程

新版方案不再设置与题目无关的全局语义编译层、评分对象或必须先完成的前置项目。TEC compiler 直接读取已经冻结的沙盒语料。冻结语料至少保留：

- canonical URL / document ID;
- 页面快照和 content hash;
- block / paragraph / table cell / product field / post / reply;
- DOM 或结构位置;

- 页面类型与来源角色；
- 链接边、回复父子边、重定向边；
- agent-visible delivery serializer 的版本与哈希。

BM25/FTS、dense embedding、结构化检索和链接遍历可以作为 compiler 内部的计算实现，也可以随规模替换；它们不出现在正式分数里，不作为 benchmark 的独立发布资产，也不要求 harness 使用。原生网站与统一公开搜索 API 仍是 agent 的研究界面。

5.2 每题提前生成的 TEC 资产

每道题必须在发布前生成并冻结下列文件：

资产	内容	是否进入计分分母
task_contract.json	用户约束、候选范围、所需输出类型	是
facets.json	query 拆出的研究 facet	是
rubric_items.jsonl	explicit 与 latent 用户/研究要求、来源、审核记录	Rubric
task_page_census.jsonl	全库扫描命中的候选页、纳入/排除状态及理由	间接
atomic_facts.jsonl	可发现核心原子事实单元	Completeness atomic coverage; Fact 裁决候选
research_units.jsonl	比较、机制、冲突、综合、教程、决策等高阶单元	Completeness research coverage
evidence_spans.jsonl	支持、反驳、冲突 span 与 source role	间接
support_routes.jsonl	同一单元允许的 OR-of-AND 证据组合	Evidence 验证
discoverability.jsonl	通过公开搜索/链接路径的发现证书	分母准入
census_counts.json	每一类页面、单元、span、URL、路线及排除项的固定条数	审计
coverage_certificate.json	检索饱和、已知 witness recall、抽检与版本信息	正式题准入

每份 TEC 都必须把实际条数写入 manifest，而不是只保存若干“推荐 witness”。最低统计包括：全库扫描的 document/block 数、各检索通道候选数、去重后候选页数、纳入与排除页数、core/supporting atomic units 数、各类 higher-order units 数、支持/反驳 spans 数、canonical URLs 数、等价证据集合数、support routes 数、公开可发现与 interface_gap 数，以及各轮新增量。

5.3 相关页面与命题闭包如何尽量做全

单一向量 ANN 的 top-k 不能被称为全量，也不能直接定义答案键。TEC 的对象不是“构题时挑中的页面”，而是相对于冻结世界、预注册检索协议与公开可发现性约束的最大可审计候选集合。构建器使用多通道 union：

1. 从 query 中拆出实体、约束、决策对象、争议点和所需输出，生成彼此独立的 facet 查询族；
2. 对冻结语料的全部 blocks 建立 BM25/FTS 与 dense vector index；dense 检索同时使用 exact/Flat 审计切片和 ANN 全量索引，避免只相信单一近似 top-k；
3. 每个 facet 生成 lexical、semantic、entity-only、predicate-only、question paraphrase、negative/contrast 六类查询，并对每类分别取候选；
4. 对商品、日期、数值、单位、类别、作者、线程和页面类型做结构化查询，补回向量模型容易遗漏的精确字段；
5. 从候选页沿链接、回复、重定向、同商品、同实体、引用和页面版本关系扩展；

6. 按来源角色分层保留候选，防止商城、Wikipedia 或某一大域在全球 top-k 中压制论坛、论文、标准和厂商页面；
7. 对候选页抽取原子命题与高阶关系，并进行实体对齐、限定条件保留、去重和 canonicalization；
8. 对每个 canonical unit 生成 value-blind 反向查询，重新扫描整个冻结语料，分别寻找支持、反驳、条件冲突和等价表达；
9. 对每个 evidence unit 枚举所有通过语义支持与来源角色检查的 canonical URLs，形成冻结等价证据集合，而不是保存唯一 URL；
10. 使用与主 compiler 不共享 query 模板和随机种子的第二遍独立 discovery pass，以及合法替代路线的合成报告做漏项挑战；
11. 对低于检索阈值的尾部按来源、分数区间和文档类型分层抽样，估计遗漏率；
12. 重复轮次，直到预注册的饱和和检查通过且所有已确认物质性 gap 均已清零。

5.3.1 向量数据库的高召回配置

向量数据库用于扩大语义召回，不单独决定答案空间。每个 block 至少保存 embedding_model_id、向量维度、归一化方式、index build hash、document/block ID 和原文 hash。构建期采用以下组合：

- 全量 ANN 检索用于规模化候选生成；
- 在每个来源域和分数区间上使用 Flat/exact 检索审计 ANN 漏召回；
- 同时检索标题、段落、表格行、结构化字段和线程回复，不只检索整页 embedding；
- 对短查询与长 query expansion 分别编码，取 union 后按 canonical page 去重；
- 不设置单一全局 top-k，而是采用 facet × query family × source role 的分层配额；
- 对数字、型号、百分比和单位始终并行执行 lexical/structured lookup，因为 dense embedding 对精确值不可靠。

正式 manifest 记录每一路候选数、去重后新增量、ANN 对 exact probe 的 recall、不同 top-k 下的饱和曲线，以及被人工挑战新发现的页面与 unit。

5.3.2 迭代闭包与停止规则

第 0 轮只使用 query 和 task contract；后续轮次只从已确认的实体、谓词、别名、冲突值和页面链接生成新查询。每一轮分别记录新增 page、atomic unit、research unit、support span、contradiction span 和 equivalence URL。

停止不能只看“连续一轮没有新增”。最低建议是：

1. 连续两轮没有新增 material core unit；
2. known witness recall 和 alternative-route recall 达到预注册门槛；
3. ANN 对 exact probe 的 recall 达标；
4. 来源分层尾部抽检没有确认的新 material unit；
5. 独立 DeepSeek-V4-Lite challenge pass 没有找到新的任务相关支持/反驳路线；
6. known_material_gap_count=0。

这里的 DeepSeek-V4-Lite 只提出遗漏候选并解释检索线索，不能直接把新 unit 写入 TEC。候选仍需绑定冻结 span，并通过独立 verifier 或人工确认。

“扫描全部 blocks”不等于让 LLM 阅读世界里的每一个 block。检索后端对全部 blocks 计算可复现分数，compiler 对多路 union 候选做语义抽取；同时对阈值以下尾部按来源与分数区间分层抽样，估计遗漏率。这样既利用整个冻结语料，又不把数百万页面全部送入昂贵 judge。

检索 query 必须尽量 value-blind：先使用 subject + predicate 检索支持与反驳候选，再由 judge 比较 value。直接把报告声称的数值写入检索词会产生 confirmation bias。

5.4 公平性边界

evaluator 的单题 corpus scanner 可以比 agent 的公开接口更强，但正式分母中的每个 core unit 必须满足：

$$Answerable(u) = 1 \quad \wedge \quad Discoverable_{public}(u) = 1.$$

Answerable 要求冻结世界中至少存在支持或可判定冲突的 span；Discoverable_public 要求至少一条支持路线能通过所有 harness 共用的公开搜索 API 或已观察页面链接被发现。

发现证书必须绑定：

- world snapshot ID；
- search API / corpus snapshot version；
- 查询文本与查询词来源；
- 返回排名和结果快照；
- top-k 与预算；
- SERP / response hash。

只被 evaluator 内部扫描找到、却无法由公开接口发现的 unit 不进入 agent 的正式分母，而进入 interface_gap 诊断。

5.5 “完整”的诚实定义

DRA 不能声称穷尽自然语言里所有可能的表述。可声称的是：

相对于冻结语料快照、版本化的多通道 census compiler、预注册停止规则、人工抽检和挑战机制，TEC 对该任务的可发现核心事实与研究关系达到 protocol-complete。

它比“几条人工 gold URL”强得多，但仍需要覆盖证书和版本治理。

正式冻结的最低条件是：known_material_gap_count=0，独立 challenge pass 中没有确认的新 core unit 或等价证据 URL，所有 core units 均有公开发现证书，并且分层尾部抽检结果与置信区间被写入 coverage certificate。这里的“0”表示已经发现并确认的 gap 必须全部修复，不是声称未来发现 gap 的概率在数学上为零。

6. TEC 中的三类冻结单元

6.1 Atomic fact units

Atomic fact 是单一、可判定、不可再安全拆分的外部命题，例如：

- 某产品的价格、重量、尺寸、规格或声明；
- 某概念的定义；
- 某用户明确报告的一段体验；

- 某页面是否提出某项营销主张；
- 某结构化列表中是否存在一个实体或属性。

每个 atomic unit 至少包含：

```
{
  "unit_id": "a_0017",
  "facet_id": "f_battery",
  "subject_id": "entity:...",
  "predicate": "battery_capacity",
  "object_norm": "6600 mAh",
  "qualifiers": {
    "model_variant": "...",
    "region": "...",
    "time": "...",
    "condition": "..."
  },
  "polarity": "positive",
  "importance": "core",
  "support_span_ids": ["s_..."],
  "contradiction_span_ids": ["s_..."],
  "source_role_policy": ["manufacturer", "retailer"],
  "discoverability_certificate_ids": ["d_..."]
}
```

Atomic units 有两个用途，但不重复计分：

1. 作为 Completeness 的 atomic coverage 分母，判断报告覆盖了多少核心事实；
2. 作为 Fact Agent 的 canonical match 和独立检索入口，判断报告主动说出的 claim 是否真实。

Fact 不再包含 atomic recall，因此“说得准”和“说得全”被正式拆开。

6.2 Higher-order research units

Higher-order unit 不是另一个原子网页字段，而是 Deep Research 必须完成的关系：

类型	例子
comparison	在同一用户约束下比较两个或多个方案的取舍
mechanism	解释“眼镜腿破坏密封 → 被动隔音下降”的因果关系
conflict	区分厂商宣传、标准含义和用户长期体验之间的冲突
cross_source_synthesis	组合商品页、社区经验与百科机制形成结论
community_pattern	不是引用一个帖子，而是准确概括多个经验的共性与边界
procedure	给出完整、可执行、顺序正确的教程
budget_allocation	在固定预算中形成方案组合并解释机会成本
decision	推荐与用户约束、证据和不确定性一致

每个 unit 必须保持原子化。例如，不创建一个“同时解释机制、比较三类产品并给出推荐”的大 unit，而拆成三个独立 relation units。这样 covered 可以是明确的语义匹配，不需要凭整体印象打分。

6.3 Explicit 与 latent rubric items

Rubric item 测的是任务履约，不是语料中出现了多少事实。它分为：

- **explicit**: 直接来自用户 query 的候选范围、预算、时间、格式、比较对象、必须回答的问题和最终输出要求；
- **latent**: 完成该类 Deep Research 合理需要、但用户没有逐名列出的步骤，例如处理冲突来源、说明关键不确定性、区分厂商声明与独立体验、让推荐和约束一致。

每个 rubric item 至少包含：

```
{
  "rubric_id": "r_0012",
  "origin": "explicit",
  "query_span": "...",
  "requirement": "在5200与6600 mAh两个版本之间解释差异",
  "importance": "core",
  "admissible_outputs": ["comparison", "conflict_resolution"],
  "forbidden_answer_leak": true,
  "author_1_status": "approved",
  "author_2_status": "approved",
  "frozen_before_reports": true
}
```

latent rubric 不能规定某个赢家、某个具体数值或某条 URL，除非这些内容本来就在用户 query 中。它只能规定需要完成的研究动作。所有 rubric 必须在看到任何 harness 报告前冻结，分歧由第三人仲裁。

7. Fact: NLI 采集、独立检索与多状态裁决

7.1 Claim 采集不是一次自由生成

Claim pipeline 以高召回提出候选，再用原文蕴含和独立 verifier 删除 extractor 幻觉。完整流程为：

```
Report
→ source-preserving sentence/span segmentation
→ high-recall atomic claim proposal
→ NLI entailment filter
→ DeepSeek-V4-Lite structural verifier
→ residual sentence sweep
→ entity/qualifier normalization
→ semantic deduplication
→ frozen report_claims.jsonl
```

Stage A: 保留来源位置的分句与候选提出

先按段落、列表项、表格行、引用锚点和句法边界切分报告，保留字符 offset、原文 hash、所属标题和邻近 citation。候选提出器对每个 span 做高召回原子化：

- 并列句拆成多个 subject-predicate-object 命题；

- 数值、单位、时间、型号、地区、版本和条件不得丢失；
- “厂商声称”“某用户报告”等 attribution 必须保留；
- 否定、可能性、范围词和比较方向必须保留；
- 推荐和主观措辞不能被错误改写成客观事实。

候选提出可以使用规则、轻量 sequence tagger 或生成模型的 union。此阶段宁可多提，不直接进入计分。

Stage B: NLI 原文蕴含过滤

对每个候选 claim，使用原报告 span 作为 premise、规范化 atomic claim 作为 hypothesis，执行 NLI：

```
premise = 报告原始句子或最小充分上下文
hypothesis = 候选原子 claim
label ∈ {entailment, contradiction, neutral}
```

只有 entailment 候选进入下一步。NLI 只验证“报告是否真的说了这个 claim”，不判断现实世界真假。对数值、否定、比较级和 attribution，另加规则一致性检查，避免 NLI 对细粒度限定词不敏感。

Stage C: DeepSeek-V4-Lite 结构检验

DeepSeek-V4-Lite 接收原始 span、候选 claim JSON 和允许的类型表，只执行以下窄任务：

1. 原文是否蕴含该 claim；
2. claim 是否原子化；
3. 是否添加、删除或改变了时间、版本、条件、否定和归因；
4. 是否属于 external atomic、derived arithmetic、higher-order relation、subjective 或 exempt；
5. 是否应拆分、重写或拒绝。

输出必须是固定 JSON：

```
{
  "verdict": "accept",
  "nli_relation": "entailed",
  "atomicity": "atomic",
  "qualifier_fidelity": "pass",
  "claim_kind": "external_atomic",
  "revised_claim": null,
  "reason_code": "all_checks_pass"
}
```

模型版本、provider、prompt、temperature、schema 和输出 hash 全部冻结。DeepSeek-V4-Lite 不允许浏览互联网，也不允许在 claim extraction 阶段看到 TEC 真值标签。

Stage D: 残差扫描与去重

为了降低漏采集，系统对每个包含实体、数字、日期、比较词、因果词或 citation anchor 的报告 span 执行 residual sweep。若一个 material span 没有任何已接受 claim 覆盖，则重新进入候选提出。

最后按 canonical subject、predicate、object、qualifiers、polarity 和 attribution 去重。重复表达只保留一个 canonical claim，但保存所有 report spans，便于审计。

7.2 报告 claim schema

```
{
  "claim_id": "c_0042",
  "report_span": {
    "start": 1830,
    "end": 1924,
    "raw_text": "...",
    "sha256": "..."
  },
  "subject": {
    "surface": "...",
    "world_entity_id": "entity:...",
    "binding": "exact"
  },
  "predicate": "battery_capacity",
  "object_norm": "6600 mAh",
  "qualifiers": {
    "model_variant": "...",
    "region": "...",
    "time": "..."
  },
  "polarity": "assert",
  "modality": "categorical",
  "attribution": "direct_fact",
  "claim_kind": "external_atomic",
  "evidence_policy": "citation_required",
  "dedup_group": "g_0012",
  "citations": ["binding:b_009"],
  "extractor": {
    "nli_model": "...",
    "nli_label": "entailment",
    "verifier_model": "DeepSeek-V4-Lite",
    "verifier_prompt_hash": "..."
  }
}
```

机器必须验证 `raw_text` 是报告原文的精确 substring，防止 extractor 自己发明 claim。任何自动重写都必须再次通过 NLI 和 qualifier check。

7.3 哪些 claim 进入 Fact

claim 类型	Fact	Evidence	Completeness	Rubric
外部原子事实	是	通常需要	可覆盖 atomic unit	视要求
来源归因事实	判断“该来源是否这样声称”	需要	可覆盖 atomic unit	视要求
比较、机制、冲突、综合	原子前提进 Fact	外部前提需要	可覆盖 research unit	可能
可复算算术/单位换算	验证计算，不当外部事实	前提需要	可作为 comparison 前提	可能
用户在 query 中给定的条件	豁免	豁免	不当外部发现	可进入 explicit rubric
纯推荐、主观措辞	否	外部前提另判	可覆盖 decision unit	可能
冻结世界外且不可裁决	不奖不罚	有快照时另判	不进入冻结分母	不自动满足

“常识豁免”必须很窄：若一句话包含具体实体、数值、时间、比较、外部机制或决定推荐的关键前提，默认需要外部证据。物理常识可以作为连接推理，但若它本身就是 query 要审核的争议点，就不能豁免。

7.4 Fact Agent 必须独立于报告引用

Evidence Agent 打开报告绑定的 URL，判断该页面是否支持 claim。Fact Agent 则必须从冻结世界独立寻找支持和反驳证据，不能把“网页上这样写”直接等同于“事实为真”。

对每个 material atomic claim，Fact Agent 执行：

1. 隐藏报告引用 URL，先用 subject + predicate + qualifiers 做 value-blind 检索；
2. 从 BM25、dense、structured 和 graph expansion 的 union 中取得候选 spans；
3. 分别构造 support、refute、conflict 和 variant-context 证据集合；
4. 按 claim 类型检查 source role，例如官方规格适合判定型号参数，论坛个例只适合证明“某用户报告过”；
5. 生成固定 evidence packet；
6. 由 DeepSeek-V4-Lite Fact verifier 在 evidence packet 内裁决；
7. 第二遍才允许查看报告绑定 URL，用于识别 attribution、版本差异和漏掉的等价证据；
8. 高影响、低置信度、冲突和 gap 进入人工复核。

Evidence packet 示例：

```
{
  "claim_id": "c_0042",
  "claim": "产品A的电池容量是6600 mAh",
  "support": [
    {"span_id": "s_101", "source_role": "retailer", "value": "6600 mAh"}
  ],
  "refute": [
    {"span_id": "s_202", "source_role": "manufacturer", "value": "5200 mAh"}
  ],
  "variant_context": [
    {"span_id": "s_303", "relation": "possible_region_or_model_variant"}
  ],
  "retrieval_manifest_hash": "...",
  "world_snapshot_id": "..."
}
```

Fact verifier 只能引用 packet 中的 span ID，不允许使用参数知识补事实。营销页面支持“厂商/商品页提出了该声明”，不自动支持“该性能已被独立验证”；论坛个例支持“该用户报告了此体验”，不自动支持“所有用户都会如此”。

7.5 Fact 的多状态裁决

Fact verdict 使用：

- true：在完整限定条件下被足够证据支持，且没有未解决的同条件反驳；
- false：被更合适来源或明确反驳 span 否定；
- conflicted：同条件下存在无法自动消解的支持与反驳；

- **unresolved**: 冻结世界有相关材料, 但不足以判断真假;
- **out_of_world**: claim 超出冻结世界可裁决范围;
- **census_gap**: 支持/反驳材料实际存在于冻结世界, 但 TEC 未收录会影响评分的 unit 或证据路线;
- **exempt**: 用户给定条件、纯主观表达或其他不应进入 Fact 的内容;
- **instrument_ambiguous**: claim extraction、实体绑定、解析或 judge 本身不可靠。

DeepSeek-V4-Lite 与第二个独立 verifier 一致且置信度超过预注册阈值时可自动接受。false、conflicted、census_gap、高影响 unresolved 和随机抽取的高置信结果进入人工审核, 用于估计自动裁决误差。

7.6 冻结世界外不惩罚

报告提到冻结世界外的数据时, 不因为 benchmark 没有收录它就自动判错:

- **out_of_world** 不进入 Fact 的分子或分母, 因此增加这类 claim 不会降低、也不会提高 Fact;
- 它不进入当前版本的 Completeness 分母, 也不能凭自身新增主分 credit;
- 若它与任务无关或只是扩写, 记录 **out_of_world_claim_rate** 后继续评分;
- 若它任务相关、物质性强, 并可能改变正确答案或正式排名, 则标记 **world_scope_gap**, 该题 withheld, 而不是处罚先发现它的报告;
- 若证据其实位于冻结世界, 只是 TEC compiler 漏掉, 则不是 **out_of_world**, 而是 **census_gap**, 必须升版并统一重算。

为防止模型用大量不可裁决 claim 逃避评测, 系统发布 out-of-world 数量、占比和 materiality, 并对高占比报告进行人工审计; 这些诊断不直接扣分。报告仍只能通过冻结的 Rubric 与 Completeness units 获得任务完成 credit。

7.7 Fact 公式

令 $\mathcal{C}_t^T$ 与 $\mathcal{C}_t^F$ 分别为报告中经裁决为 true 和 false 的去重 material atomic claims, $m(c)$ 为预先定义的 materiality 权重, 则:

$$Fact_t = \frac{\sum_{c \in \mathcal{C}_t^T} m(c)}{\sum_{c \in \mathcal{C}_t^T \cup \mathcal{C}_t^F} m(c)}.$$

若没有任何 in-scope、可裁决的 material atomic claim, 则 $Fact_t = 0$; 这是“没有产生可测事实”的结果, 不是对 out-of-world claim 额外扣分。事实覆盖率不再进入 Fact, 而进入 Completeness。

同时强制发布:

- **fact_true_rate**;
- **fact_false_rate**;
- **fact_conflict_rate**;
- **fact_unresolved_rate**;
- **out_of_world_claim_rate**;
- **fact_adjudication_coverage**;
- 自动裁决与人工裁决的分歧率。

7.8 表外 claim 或 URL 的版本治理

正式 scorer 只查冻结表。报告中的未匹配 claim 先标记为 `pending_table_match`:

1. 若它只是已有 unit 的新表述, matcher 映射到已有 canonical unit;
2. 若它超出冻结世界, 标记 `out_of_world`, 不奖不罚;
3. 若它被世界内证据明确反驳, 按 `false` 处理;
4. 若它是真实、任务相关、物质性的新 unit, 且证据位于冻结世界, 则触发 `census_gap`;
5. 若它揭示冻结世界本身缺少完成任务所需的材料, 则触发 `world_scope_gap`;
6. 两类 material gap 都使该题退出当前正式聚合, 修复后对全部报告统一重算。

新 URL 使用同样原则, 但要区分:

1. 已登记页面的重定向、镜像别名或 canonicalization 结果, 确定性归并;
2. URL 真实但内容不支持对应命题, Evidence binding 失败;
3. URL 位于冻结世界外且当前 evaluator 无快照, 标记 `out_of_world_url`, 不自动判 claim 为假;
4. URL 确实为已有 evidence unit 提供了此前漏登记的合法冻结 span, 触发 `evidence_equivalence_gap`。

任何 gap 都不能在当前版本临时补进等价集合并只给发现者得分。正确做法是冻结当前任务结果, 补齐 TEC、重新执行反向枚举和挑战审计, 提升版本, 再统一重算所有 harness。

8. Evidence: 接替旧 ProofOfFetch 槽

8.1 为什么不能只按 URL 计

一个 URL 可以支持二十个 claims, 也可能一个都不支持。仅计算 $|\text{cited} \cap \text{fetched}| / |\text{cited}|$ 会漏掉:

- 抓过页面但引用位置与 claim 错绑;
- 页面相关但不支持附近说法;
- 页面明确反驳报告;
- 参考文献区堆 URL, 没有任何就地引用;
- 只看到搜索 snippet, 却写出超出 snippet 的深层结论。

因此, Evidence 同时使用两个分母: citation binding precision 与 claim/unit evidence coverage。

8.2 Citation binding

一个 binding 是:

```
报告 claim/research-unit span
× 文内 citation anchor
× canonical URL
× 被观察的 source span
```

只列在 bibliography、没有文内 anchor 的 URL 不构成支持 binding, 但仍进入 URL 完整性诊断。

8.3 一个 binding 何时通过

对 binding b , 定义:

$$Pass(b) = Valid(b) \wedge Observed(b) \wedge Bound(b) \wedge Supports(b) \wedge RoleOK(b).$$

- **Valid**: URL 属于冻结 registry, canonicalization 成功;
- **Observed**: 本次运行账本证明 agent 实际收到支持文本;
- **Bound**: 文内引用在局部上绑定对应 claim, 而不是参考文献漂移;
- **Supports**: 观察到的 span 语义支持完整 claim;
- **RoleOK**: 来源角色足以支持 claim 的措辞与强度。

Provenance 只判断 URL 是否真实存在、可规范化并有冻结快照。URL 如何被搜索发现、本次是否打开以及收到的是 snippet 还是完整页面, 由 Execution Audit 分别报告; 其中“是否实际观察到足够文本”继续作为 Evidence 的必要条件。

8.4 Evidence Agent: NLI 初筛、DeepSeek-V4-Lite 复核与人工抽查

Evidence Agent 只判断“报告 claim 与绑定页面之间的支持关系”, 不判断世界最终真相。对每个 binding:

1. 根据 citation anchor 找到最小 report claim span;
2. 从运行账本恢复 agent 实际看到的最小 source span;
3. 以 source span 为 premise、report claim 为 hypothesis 执行 NLI;
4. contradiction 直接进入失败候选, neutral 进入 insufficient 候选, entailment 进入复核;
5. DeepSeek-V4-Lite 检查数值、单位、否定、时间、型号、条件、attribution 和 source role;
6. 输出 support / refute / insufficient / wrong_scope / wrong_role / ambiguous;
7. 高影响 claim、模型分歧、低置信结果和随机样本交由人工检查。

NLI 负责高吞吐初筛, DeepSeek-V4-Lite 负责细粒度限定词和来源角色, 人工负责校准边界。三个阶段都只能使用冻结 source span, 不允许自由上网或使用模型参数知识补证据。

8.5 整页与 snippet 的统一规则

观察对象不是“URL 字符串”, 而是 agent 实际收到的 bytes:

- 整页抓取: 日志保存 status 200、body hash、delivery serializer 与可定位 blocks;
- 搜索 snippet: 日志必须保存 snippet 原文或 content-addressed blob, 而不只是 URL;
- 仅看到 URL: 没有内容观察, 不能支撑 claim。

当 snippet 本身完整包含支持 claim 的 span 时, 它是合法的 observed evidence, 可以给满 binding credit。若 claim 超出 snippet 内容, 即使 URL 真实存在, 也记 insufficient_observation, binding 失败。

这不会不公平地偏袒 snippet-only harness: 浅 factoid 可以由 snippet 支持; 需要上下文、表格、冲突或长证据链的主张必须读取更完整内容。能力差异出现在真正需要能力的位置, 而不是先给所有 snippet harness 固定扣 0.28。

8.6 Evidence 公式

令：

- $\mathcal{B}_t$ ：报告中的全部 material in-text citation bindings；
- $\mathcal{B}_t^{pass}$ ：通过上述五腿的 bindings；
- $\mathcal{X}_t^{cite}$ ：报告中全部 citation-required atomic claims 与 higher-order units；
- $\mathcal{X}_t^{grounded}$ ：至少有一个 passing binding 的 units。

$$P_t^{evidence} = \frac{|\mathcal{B}_t^{pass}|}{|\mathcal{B}_t|}, \quad R_t^{evidence} = \frac{|\mathcal{X}_t^{grounded}|}{|\mathcal{X}_t^{cite}|}.$$

$$Evidence_t = \begin{cases} \frac{2P_t^{evidence} R_t^{evidence}}{P_t^{evidence} + R_t^{evidence}}, & P_t^{evidence} + R_t^{evidence} > 0, \\ 0, & \text{otherwise.} \end{cases}$$

若正式任务要求外部研究而报告没有 citation，则 $Evidence_t = 0$ 。若运行日志缺失或无法完整归责，整个 run 的正式 Truth 被 withheld；不把 Evidence 记成 0，也不对其他轴重归一化。

8.7 原始 PoF 留在哪里

以下指标继续发布，但不进入 Quality：

$$FetchRate_t = \frac{|CitedURLs_t \cap Fetched200_t|}{|CitedURLs_t|}.$$

同时报告：

- snippet_observation_rate；
- full_page_observation_rate；
- fetched_but_unused_rate；
- search_returned_but_unopened_rate；
- quote_fidelity_text_v1，仅诊断；
- 各 harness 的 observation tier 分布。

text_v1 不得回落为正式 Evidence，也不得再以 ProofOfFetch 名义混入同一榜单。

9. Completeness：相对可发现内容集合的覆盖率

9.1 Completeness 不再与 Fact 重复

Fact 只测报告主动说出的可裁决事实是否准确；Completeness 接管全部 coverage，回答：

相对于冻结世界中按照预注册协议能够发现、能够回答且与任务相关的内容集合，报告覆盖了多少？

它同时覆盖 atomic facts 与 higher-order research units，但分层计算，防止某一类数量特别多的单元淹没其他研究能力。

9.2 Atomic 与 research unit coverage

对每个 TEC unit u ，定义：

$$Covered_t(u) = 1$$

当且仅当报告中存在一个去重 span：

1. 与 u 的 subject、predicate/relation、object、direction、condition、polarity 和 attribution 匹配；
2. 没有被同条件 contradiction span 明确反驳；
3. 对 comparison/decision unit，包含要求的候选与约束；
4. 对 conflict unit，表达冲突双方及适用边界；
5. 对 cross-source unit，不只复述单一来源；
6. 对 atomic unit，不能只出现实体名而没有对应事实。

Completeness 的 unit match 不要求报告复现构题 URL。只要报告内容与 canonical unit 匹配，并满足相应 Evidence 要求，就可以通过合法替代路线覆盖。

9.3 分层宏平均

令 $\mathcal{U}_{t,f,g}$ 为任务 t 、facet f 、unit type g 下的 core units，其中 g 包括 atomic、comparison、mechanism、conflict、synthesis、procedure 和 decision。先计算：

$$C_{t,f,g} = \frac{\sum_{u \in \mathcal{U}_{t,f,g}} Covered_t(u)}{|\mathcal{U}_{t,f,g}|}.$$

设 $\mathcal{K}_t = \{(f, g) : |\mathcal{U}_{t,f,g}| > 0\}$ ，则：

$$Completeness_t = \frac{1}{|\mathcal{K}_t|} \sum_{(f,g) \in \mathcal{K}_t} C_{t,f,g}.$$

这样，一个包含大量商品字段的 facet 不会压制只有少数机制或冲突 unit 的 facet。题目中不适用的类型不进入平均。

9.4 “最大子集”的可审计含义

这里的最大子集不是数学意义上穷尽冻结世界的所有自然语言命题，而是：

由 BM25、dense vector、structured lookup、graph expansion、反向检索、来源分层、独立 challenge pass 和尾部抽检共同建立的 protocol-complete discoverable set。

正式发布时，每题必须提供：

- 各检索通道召回的页面与 unit 数；
- 每轮新增量与饱和曲线；
- known witness 与 alternative-route recall；
- ANN 相对 exact probe 的 recall；
- source-stratified tail audit；

- core unit 的公开 discoverability certificate;
- 已知 material gap 为 0 的冻结状态。

9.5 深度如何进入 Completeness

不另加一个凭整体印象评分的 Depth 标量。Depth 通过需要多步研究的 unit 类型进入：

- 单一页面复述只能覆盖 atomic fact;
- comparison 需要对齐多候选与同一约束;
- mechanism 需要方向、条件和因果边;
- conflict 需要支持与反驳双方;
- cross-source synthesis 需要多个来源角色;
- decision 需要把证据、用户约束、不确定性和结论连接起来。

10. Rubric Fulfillment: 用户要求与潜在研究要求

10.1 两类 rubric

对每个任务构建：

$$\mathcal{R}_t = \mathcal{R}_t^{\text{explicit}} \cup \mathcal{R}_t^{\text{latent}}.$$

explicit 直接来自 query，不得改写其语义；latent 只能补充完成该任务所必需的研究动作，不能预埋参考答案。候选 latent rubric 由 query-only Rubric Agent 提出，DeepSeek-V4-Lite 检查是否必要、是否答案泄漏、是否与其他项重复，再由两名标注者在不看报告的前提下审核冻结。

10.2 Rubric item 的通过条件

每个 rubric item r 的 verdict 为：

- fulfilled: 报告明确完成要求;
- partially_fulfilled: 完成可拆分要求中的一部分;
- not_fulfilled: 未完成;
- not_applicable: 构建期确认该题不适用，冻结后不能临时改;
- ambiguous: judge 无法可靠判断，进入人工复核。

core rubric 应尽量拆成可二元判断的原子要求；只有天然可分段的 procedure 或多候选比较允许预注册部分分。

10.3 Rubric 公式

令 $v_t(r) \in \{0, 0.5, 1\}$, $q(r)$ 为冻结 importance 权重，则：

$$Rubric_t = \frac{\sum_{r \in \mathcal{R}_t} q(r) v_t(r)}{\sum_{r \in \mathcal{R}_t} q(r)}.$$

Rubric judge 不能把“提到了很多相关事实”直接当作满足用户要求。例如，报告列出大量电池参数，却没有按预算比较、处理 5200/6600 mAh 冲突或给出最终建议，则 Completeness 的部分单元可能通过，但对应 Rubric 仍失败。

10.4 防止 latent rubric 变成隐藏答案

每个 latent rubric 必须满足：

1. 能从 query、任务类型和一般研究规范解释其必要性；
2. 不指定某个答案赢家、具体数值或特定 URL；
3. 在看到所有 harness 报告前冻结；
4. 有双人审核与分歧仲裁记录；
5. 通过 leave-one-rubric-out 和人类适当性评估；
6. 若正式运行暴露必要但漏掉的 rubric，触发 rubric_gap 并统一升版重算。

11. Provenance：只测 URL 是否真实存在

11.1 定义

令 Z_t 为报告引用的 canonical evidence URL 集。对 URL z ：

$$ValidURL(z) = Canonicalized(z) \wedge InRegistry(z) \wedge SnapshotAvailable(z).$$

其中 SnapshotAvailable 要求冻结 HTTP 200 页面或可验证的等价成功快照，并绑定 content hash。若页面在冻结世界外且 evaluator 无法取得快照，标记 out_of_world_url，不自动把相关 claim 判假，但该 URL 不能获得 Provenance credit。

$$Provenance_t = \frac{\sum_{z \in Z_t} ValidURL(z)}{|Z_t|}.$$

当 $|Z_t| = 0$ 时定义 $Provenance_t = 0$ 。

11.2 发现与抓取过程单独审计

URL 是否通过 search API 返回、是否由页面链接发现、是否被实际打开，仍然重要，但不再混入 URL existence 的定义。Execution Audit 单独发布：

- search_discovered_url_rate;
- link_discovered_url_rate;
- guessed_real_url_rate;
- fetched_200_rate;
- search_returned_but_unopened_rate;
- snapshot_hash_match_rate。

Evidence 中的 Observed 继续要求本次运行实际看到足够支持 claim 的文本。因此，一个猜中的真实 URL 可以获得 Provenance，但若没有观察内容，Evidence 仍失败。

11.3 为什么与 Evidence 不相同

- Provenance 按 URL，问“这个来源是否真实存在并有冻结快照?”;
- Evidence 按 binding 与 claim，问“本次观察到的页面内容是否支持报告说法?”

情况	Provenance	Evidence
URL 真实，但引用内容不支持 claim	高	低
URL 真实且支持，但本次没有观察到内容	高	低
URL 伪造或无法规范化	低	无 passing support
URL 真实、实际观察、正确绑定并支持	高	高

URL 伪造会降低 Provenance，并使相关 binding 无法通过。另行报告 fabricated URL 数量和比例，便于解释重复影响。

12. 最终合成与权重




图 3: 五个分数使用不同分母: Provenance 作为 URL 有效性外层，四个互补质量轴进入 Quality。

12.1 候选正式公式

$$Quality_t = \frac{1}{4}Fact_t + \frac{1}{4}Evidence_t + \frac{1}{4}Completeness_t + \frac{1}{4}Rubric_t.$$

$$Truth_t = Provenance_t \cdot Quality_t.$$

不再使用 $Provenance^{1.5}$ ；指数没有独立构念，直接乘法最容易解释：

一份报告在事实准确、证据绑定、信息覆盖和任务履约上获得的质量，只有在其引用 URL 真实存在并具有冻结快照时才兑现。

12.2 为什么先等权

四个轴已经经过构念去重，但当前没有证据证明其中任何一轴的一分应值另一轴的固定倍数。使用两位小数只会制造错误精度。

等权版本必须配套：

1. 发布四个 raw axes；
2. 在四维权重 simplex 上做系统敏感性分析；
3. 报告 top-k 排名稳定率、两两顺序翻转率和各 harness 的可胜区域；
4. 使用独立人类内容偏好只验证排序相关性，不在 formal test 上拟合权重；
5. 额外报告最低轴门槛与几何平均 ablation，检查线性加权是否让关键短板被其他轴补偿；
6. 任何权重或聚合规则修改都提升 scorer major version，并重算全部历史输出。

12.3 Legacy ablation

同一批新轴可以额外计算：

$$Truth_t^{legacy\ weights} = Provenance_t (0.39Fact_t + 0.28Evidence_t + 0.33Completeness_t).$$

该值仅用于回答“排名是否依赖权重”，不作为首个正式榜默认。

12.4 缺失轴不重归一化

若某个 formal run 的 ledger、report、registry snapshot 或 TEC manifest 不完整：

- Truth_t 标记 withheld；
- 不把缺失轴当 0 诬罚 agent；
- 不把剩余轴重归一化后伪装成同一指标；
- 修复基础设施后重跑或重算。

这保证所有榜单行使用同一个测量工具。

12.5 跨任务聚合

对固定任务集 $\mathcal{T}$ ：

$$Score_h = \frac{1}{|\mathcal{T}|} \sum_{t \in \mathcal{T}} Truth_{h,t}.$$

使用 task macro-average，避免 TEC unit 数量多的题获得更大任务权重。基础设施不可归责失败被 withheld；可归责的超时、空报告或 harness 失败按预注册运行规则计 0。

13. 写作 Elo 单独报告

写作 jury 只比较：

- 语言是否清楚；
- 结构是否易读；
- 术语是否一致；
- 是否有不必要重复；
- 表格与段落是否帮助读者理解。

它不得重新判断引用真假、Fact、Evidence、Completeness 或 Rubric。建议使用位置交换的 pairwise judging, 拟合 Bradley-Terry 分数，同时发布：

- judge-human agreement；
- 双人 Cohen's kappa / Krippendorff alpha；
- position bias 与 length bias；
- bootstrap confidence interval。

Elo/BT 依赖参赛池，是展示性和写作偏好指标，不与 Truth 相乘，也不作为隐藏 tie-break。

正式裁判 instruction、JSON 输出合同、位置交换、长度窗口和 Bradley-Terry 拟合规则冻结在 DRA_WRITING_ELO_JUDGE_INSTRUCTION_2026-07-23.md，协议名为 dra_writing_elo_v1。

14. 失败类型的唯一责任表

失败类型	Fact	Evidence	Completeness	Rubric	Provenance	诊断
fabricated_url	内容另判	无有效 binding	相关 unit 可能未 grounded	内容另判	失败	数量/比例
guessed_real_url	内容另判	只有实际观察并支持才通过	内容另判	内容另判	URL 存在则通过	discovery diagnostic
unobserved_citation	内容另判	失败	内容匹配可诊断但未 grounded	内容另判	URL 存在则通过	snippet/full-page 状态
wrong_binding	内容可能正确	失败	内容若正确可匹配	内容另判	不受影响	binding error
unsupported_citation	claim 可能为真	失败	内容另判	内容另判	不受影响	support verdict
false_claim	失败	相关 binding 通常失败	对应 unit 不覆盖	可能失败	不受影响	critical claim flag
omitted_atomic_fact	不受影响	不适用	atomic coverage 下降	视要求	不适用	atomic miss
omitted_comparison/mechanism	原子前提另判	不适用	research coverage 下降	可能失败	不适用	unit-type miss
missed_explicit_requirement	不受影响	不受影响	内容另判	失败	不受影响	explicit rubric miss
out_of_world_claim	不奖不罚	有快照时另判	不进入冻结分母	不自动满足	URL 另判	数量/占比
fetchd_but_unused	不受影响	无 credit	不受影响	不受影响	URL 可能有效	process waste
census_gap/rubric_gap	题目 withheld	题目 withheld	题目 withheld	题目 withheld	不适用	触发版本修复
world_scope_gap	不处罚报告	不处罚报告	题目 withheld	题目 withheld	URL 可另判	修复世界或删除题目

这张表不是说所有失败完全统计独立，而是规定每个轴的主问题，防止用同一个 URL 集合同时解释所有质量维度。

15. 极端案例推演

15.1 空报告或纯格式空壳

- 没有可裁决事实，Fact 为 0；
- Evidence 为 0；
- Completeness 为 0；
- Rubric 为 0；
- Provenance 为 0；
- Truth 为 0。

15.2 一条完全正确且有证据的短答案

- Fact 可以很高，因为说出的事实准确；
- Evidence 可高；
- 相对 atomic + research unit bank 的 Completeness 很低；
- 若用户要求完整比较和推荐，Rubric 也低；
- 因此不会因为“只说一句真话”接近满分。

15.3 宽泛事实堆砌，没有比较和结论

- Fact 可高；
- Evidence 可高；
- comparison/mechanism/decision units 大量缺失，Completeness 低；
- 用户要求的比较或结论未完成时，Rubric 低；
- 这正是 Deep Research 与普通 fact collection 的区别。

15.4 逻辑漂亮但靠参数知识，没有本次引用

- Fact 和 Completeness 可能在内容上较高；
- Evidence 低；
- 无 citation 时 Provenance=0；
- Truth=0，明确测出“说对了但没有证明是本次研究所得”。

15.5 抓了许多页面但引用全错

- raw FetchRate 高；
- Evidence binding precision 低；
- raw fetch 不再直接买质量分。

15.6 Snippet-only harness 完成浅事实核对

- 若日志中的 snippet 完整支持 factoid，Evidence 可通过；

- FetchRate 为 0，作为诊断披露；
- 若它尝试基于 snippet 写长上下文结论，Observed/Supports 失败。

15.7 使用不同于构题路线的真实页面

正式 TEC 应已通过反向全语料扫描把它列入 support equivalence class，因此正常得分。若未列入而经仲裁确认有效，触发 census gap 和统一重算；不能只给该 harness 私下开例外。

若该页面确实位于冻结世界外，相关 claim 标记 out_of_world，不奖不罚；只有当它任务相关、物质性强且会改变正确答案时，触发 world_scope_gap 并暂停该题。

15.8 一个伪造 URL 混在十个真实 URL 中

- Provenance 约按比例下降；
- 相关 claim 没有 passing binding 时 Evidence recall 下降；
- 不把整题一票否决；
- fabricated count 单列，读者能直接看到诚信问题。

15.9 报告内容优秀但文风很差

- Truth 可以很高；
- writing Elo 低；
- 两个结果共同描述报告，而不是相互污染。

15.10 运行日志坏了

- 不能知道 agent 是否实际看到证据；
- 该 run withheld，而不是 Evidence=0 或自动退回 text_v1；
- 修复后重跑。

15.11 引用页面支持说法，但世界证据反驳

- Evidence 可以高，因为引用页面确实这样写；
- Fact 为低或进入 conflicted，因为独立多来源证据不支持该结论；
- 如果差异来自型号、地区或时间，Fact Agent 必须保留限定条件，不得把版本冲突误判为 false；
- 这正是 Fact 与 Evidence 分开的必要案例。

16. Census gap 与版本治理

16.1 为什么不能把 on-demand 当正常功能

如果正式输出经常找到表外有效证据，说明构建期“相关页面闭包”和等价类没有做全。把它静默补进当前报告会产生三个问题：

- 分母在不同 harness 之间变化；
- 后跑系统比先跑系统获得更完整答案键；

- benchmark 无法复现。

因此, on-demand matcher 只作挑战与审计入口。

这里的 matcher 只能回答“当前版本是否暴露了资产缺口”, 不能改变当前版本的分子或分母。正式计分路径中不存在 `dynamic_append=true`。

16.2 挑战流程

```
report produces unmatched material claim / URL
→ deterministic canonicalization and duplicate check
→ frozen-world evidence review
→ task-relevance review
→ if invalid/irrelevant: score normally
→ if outside frozen world and non-material: neutral out_of_world
→ if outside frozen world and material: world_scope_gap
→ if valid and already equivalent: compiler/matcher bug
→ if valid new claim: atomic_or_relation_census_gap
→ if valid new supporting URL: evidence_equivalence_gap
→ if valid missing requirement: rubric_gap
→ task status = needs_recompile
→ TEC version bump
→ recompute every historical report for that task
```

不允许只修改某一个系统的分数。每次修复必须留下 before/after manifest hash、unit diff、受影响报告数量和排名变化。

16.3 防止恶意 DoS

只有同时满足以下条件才触发 census/rubric gap:

1. claim/URL 在冻结 registry 中可核验;
2. 证据 span 确实支持完整命题;
3. 命题与 query 的正式 facet 相关;
4. 它不是已有 unit 的表面改写;
5. 它会新增 core atomic unit、research unit、rubric item 或 equivalence member。

虚构、无关、重复和非物质性的 out-of-world 内容不触发升版。已确认的任一种 material gap 都必须清零后才能重新发布该任务; 不设置按缺口比例忽略问题的容忍阈值。

17. 校准与验证计划

17.1 TEC corpus scan 召回

测试	数据	建议准入目标
known witness recall	构题时已知、冻结后隐藏的 support spans	各域 Recall@candidate ≥ 0.95
alternative-route recall	人工/独立检索找到的替代页面	false reject ≤ 0.05
source-stratified recall	商城、论坛、百科、论文等	每类单独达标，不只看总体
ANN exact-probe recall	分层 Flat/exact 检索切片	达到预注册门槛并报告置信区间
saturation	每轮新增页面/unit/equivalence member	曲线达到预注册平台期
tail audit	阈值以下来源/分数分层样本	无确认 material 漏项
parser round-trip	表格、回复树、字段、链接	结构化关键字段精确率/召回率 ≥ 0.99
discoverability	公开 search API 证书回放	全部可重放

数值是工程 go/no-go 候选，应先在 Dev-14 上验证后预注册；未达标不能把任务标为 frozen。

17.2 Claim extractor

对 Dev-14 与多 harness 报告分层抽样，双人标注 claim 边界、类型、豁免类别与去重组：

- exact/overlap claim boundary F1；
- NLI entailment precision/recall；
- qualifier fidelity，单独覆盖数值、单位、否定、时间、型号和 attribution；
- DeepSeek-V4-Lite accept/rewrite/reject 与人工一致率；
- claim-kind macro-F1；
- material external claim recall；
- duplicate collapse precision；
- residual sentence escape rate；
- extractor escape rate。

候选准入目标：边界 F1 ≥ 0.90 ，类型 macro-F1 ≥ 0.85 ，material claim recall ≥ 0.95 。

17.3 Fact 与 Evidence judge

构建平衡校准集，覆盖：

- supported；
- contradicted；
- true / false；
- conflicted / unresolved；
- out_of_world / census_gap；
- wrong binding；
- mixed / source-role conflict；
- snippet sufficient / insufficient；
- paraphrase 与数值单位等价。

每项由两名独立标注者判断，分歧仲裁。报告：

- human-human Cohen's kappa;
- Krippendorff alpha;
- judge-human macro-F1;
- 各类别 precision/recall;
- false acceptance / false rejection;
- 置信区间。

候选准入目标: 三分类 $\text{kappa} \geq 0.70$, judge macro-F1 不低于 human agreement band, contradicted precision ≥ 0.90 。

Fact 与 Evidence 必须分别校准: Evidence judge 只能看报告 claim、绑定 URL 和本次观察 span; Fact judge 只能看独立检索 evidence packet, 并在第一遍隐藏报告引用。若两者共享同一输入, 实验不能证明两个构念已经分开。

17.4 Rubric judge

对 explicit 与 latent rubric 分层标注, 至少报告:

- query-to-explicit-rubric recall;
- latent rubric appropriateness;
- answer-leak rate;
- duplicate rubric rate;
- rubric-human macro-F1;
- fulfilled / partial / not_fulfilled 混淆矩阵;
- 双人 agreement 与分歧仲裁率。

任何 latent rubric 若包含参考答案赢家、报告特有措辞或非 query 必需的具体数值, 直接判定为泄漏并禁止冻结。

17.5 运行账本注入测试

程序化构造:

- fabricated URL;
- guessed real URL;
- search-returned but unopened;
- snippet sufficient;
- snippet truncated;
- full page fetched;
- wrong binding;
- bibliography bleed;
- log damage;
- cross-run contamination。

集合分类、hash、run isolation 和 withhold code 应接近确定性全部通过。

17.6 端到端不变量

正式 scorer 必须通过：

- 添加一个正确、已观察、支持且任务相关的 unit 不得降低分数；
- 添加一个错误 claim 不得提高 Fact；
- 添加一个 out-of-world claim 不得改变 Fact；
- 只增加无关 fetch 不得提高 Evidence；
- 替换为同一 equivalence class 的证据 URL 不得降低分数；
- 删除一个 core atomic 或 research unit 不得提高 Completeness；
- 删除一个已满足的 core rubric 不得提高 Rubric；
- 一条 fabricated URL 不得增加任何主轴；
- 缺日志不得自动变成 0 或 text_v1；
- 改变 harness 不得改变同一任务的 TEC 分母。

17.7 权重敏感性

在 simplex $w_F + w_E + w_C + w_R = 1$ 上采样，至少报告：

- 榜首稳定区域；
- top-3 集合稳定率；
- 两两 harness 顺序翻转概率；
- leave-one-axis-out 排名；
- equal weight 与 legacy weight 的 Kendall/Spearman 相关；
- 结论依赖某一狭小权重区域时的警告。

18. 一道任务的示意产物

以下数字仅示意 schema，不是现有题目的正式统计：

```
task_id: headphone_glasses_flight_demo
tec_version: 1
corpus_snapshot: corpus-v1-demo

atomic_fact_bank:
  total_core: 18
  by_facet:
    seal_and_glasses: 4
    anc_low_frequency: 3
    comfort: 4
    portability: 3
    battery: 4

research_units:
  total_core: 13
  by_type:
    comparison: 3
```

```
mechanism: 2
conflict: 2
community_pattern: 2
cross_source_synthesis: 2
decision: 2

rubric_items:
  total_core: 7
  explicit: 4
  latent: 3
  double_review_status: passed

evidence:
  support_spans: 61
  contradiction_spans: 14
  canonical_urls: 29
  support_routes: 37

certificates:
  answerable_core_units: 31
  discoverable_core_units: 31
  witness_recall: 1.0
  ann_exact_probe_recall: 0.98
  out_of_world_policy: neutral
  human_audit_status: passed
```

正式任务必须把真实统计直接写入 manifest 和题目 factsheet, 不能只在论文中口头描述。

19. 实施路线

Phase 0: 公式与 schema 锁定

- 固定本文件中的五个主对象: Atomic Fact、Evidence Binding、Completeness Unit、Rubric Item、URL Provenance;
- 固定 NLI 与 DeepSeek-V4-Lite 的模型快照、prompt、JSON schema 和人工升级规则;
- 固定空分母、withhold、census gap 与版本规则;
- 发布 JSON Schema 和最小 oracle cases;
- 不先锁小数权重之外的隐含阈值。

Phase 1: 单题完整 TEC

选择一道人类已充分理解、三类来源齐全的 dev 题:

- 从 query-only 启动 census;
- 禁止用旧 graph 的 URL 作为检索白名单;
- 旧 witnesses 只作最终 recall probe;
- 列出全部 atomic facts、research units、support/contradiction equivalence classes;
- 编译 explicit/latent rubric 并完成双人盲审;

- 运行 ANN/exact probe、来源分层尾部抽检和独立 challenge pass;
- 人工审计完整 manifest;
- 用至少三份极端 mock 报告跑通公式。

Phase 2: 真实 harness pilot

- 选一个强 harness 与一个 snippet-heavy harness;
- 使用相同任务、搜索 API、TEC 和 scorer;
- 检查 Fact/Evidence/Completeness/Rubric 是否各自抓住预期失败;
- 检查 out-of-world claim 是否保持不奖不罚;
- 检查新 URL 是否都被 census 枚举;
- 若出现 census gap, 返回 Phase 1 修 compiler, 而不是给某份报告临时补分;
- 重新发布前必须扩展反向全库枚举, 并对问题所有历史报告统一重算。

Phase 3: Dev-14

- 对 14 道题全部生成 TEC;
- 双人抽查 claim/research-unit/rubric 分类;
- 完成 judge calibration、kappa 和账本注入测试;
- 发布权重敏感性;
- 冻结 scorer v1。

Phase 4: 56 题扩展

- 批量 census;
- 按域和 unit type 分层抽检;
- 自动输出每题 coverage certificate;
- 不通过证书的题进入 quarantine;
- 正式集冻结后再跑全部 harness。

Phase 5: 榜单与论文

主表固定发布以下列:

Harness		Truth		Fact		Evidence		Completeness		Rubric		Provenance		Writing Elo
---------	--	-------	--	------	--	----------	--	--------------	--	--------	--	------------	--	-------------

附录再报告:

- fabricated / guessed / unobserved / wrong-binding / contradicted rates;
- conflicted / unresolved / out-of-world rates;
- unit-type coverage;
- explicit/latent rubric fulfillment;
- full-page / snippet observation tier;
- census coverage certificate;
- judge calibration;
- 权重敏感性;
- 任务级明细。

20. 可能的 reviewer challenge 与回答

Challenge 1: TEC 仍然是 LLM 生成的 rubric

回答: TEC 不是自由文本评分标准, 而是由冻结世界 span 支撑的、类型化事实和关系总账。LLM 负责提出和归一化, 所有 unit 必须带可核查 support/contradiction span、hash、source role、discoverability certificate 和人工抽检结果。主分分母在运行前冻结, 不由 judge 临时决定。

仍需诚实承认: 关系 unit 的语义归一化包含模型判断, 因此必须报告 human agreement 与 compiler error rate。

Challenge 2: 你们真的枚举了全部相关事实和 URL 吗

回答: 不声称逻辑上穷尽所有自然语言命题, 声称 protocol-complete。证据包括 BM25/dense/structured/graph union、ANN 对 exact probe 的召回、全语料反向扫描、饱和曲线、已知 witness recall、source-stratified tail audit 和 census-gap 挑战机制。任何确认 gap 都触发版本修复和全量重算。

Challenge 3: evaluator 的向量库比 agent 强, 不公平

回答: 测试 oracle 比被测程序更强是正常的; 不公平只会发生在 evaluator 内部扫描找到的目标被放进 agent 无法发现的分母。因此, 每个正式 core unit 必须有公开 API 的发现证书; 私有扫描能力用于建立/验证标准, 不作为 agent 的隐藏工具。

Challenge 4: Fact 与 Completeness 都是 recall

回答: 新版 Fact 不含 recall, 只测报告主动说出的、可裁决原子 claims 的事实准确率; Completeness 独立测冻结 atomic + higher-order unit universe 的覆盖率。因此 Fact 回答“说出的对不对”, Completeness 回答“该说的覆盖了多少”。

Challenge 5: Evidence 与 Provenance 都在罚引用

回答: Provenance 的分母是 URL, 只测 URL 是否真实存在、可规范化并有冻结快照; Evidence 的分母是 binding 和 citation-required report units, 测本次观察、局部绑定和语义支持。真实但错误引用呈现 Provenance 高 / Evidence 低; 发现和抓取路由 Execution Audit 单独报告。

Challenge 6: 为什么用加权和, 为什么等权

回答: 报告级加权和是候选产品目标; 等权是没有效用函数时最少承诺的起点, 不是假装最优。四个 raw axes、legacy ablation、最低轴门槛、几何聚合和四维 simplex 敏感性全部公开。若主要结论依赖狭窄权重范围, 论文不得声称稳健。

Challenge 7: 零 citation 但内容全对为什么 Truth 为零

回答：DRA 测的是 evidence-grounded research，不是闭卷知识问答。零 citation 的报告可能事实正确，但无法证明内容来自本次研究；Fact/Completeness 明细仍可显示其内容能力，正式 Truth 为零是构念选择而非事实真假判决。

Challenge 8: 为什么不用一个额外 Depth 主轴

回答：Depth 已被具体化为高阶 research unit coverage；再加一个整体 judge depth 分会重复、引入风格偏差且降低自动化。若未来发现 unit coverage 与人类深度判断相关性不足，可以把整体 depth 保留为验证面板，而不是立即加入主分。

Challenge 9: 表外 claim 会让榜单频繁重算

回答：先区分 out_of_world 与 census_gap。冻结世界外、非物质性的 claim 不奖不罚，不触发重算；证据实际在冻结世界内而 TEC 漏掉，或外部事实物质性强到改变任务答案时，才触发 gap。频繁 material gap 说明任务不应冻结。每次修复统一重算，优先保证公平。

Challenge 10: 为什么相信 NLI 与 DeepSeek-V4-Lite

回答：两者都不是最终真值来源。NLI 只验证候选 claim 是否被报告原文蕴含；DeepSeek-V4-Lite 只在固定 schema 与冻结 evidence packet 内检查原子性、限定词、支持、反驳和冲突。所有输出绑定 span ID、模型快照和 prompt hash，并通过双人标注、第二 verifier、高影响人工审核和随机抽检校准。

Challenge 11: latent rubric 会不会成为隐藏答案

回答：latent rubric 只描述必要研究动作，不包含答案赢家、特定数值或 URL。它由 query-only agent 在看报告前提出，经答案泄漏检测和双人审核后冻结。任何运行后新增的必要要求都触发 rubric_gap 和统一升版，不能针对单个系统临时加减分。

21. 需要立即拍板的规格

本稿已经给出推荐默认，实施前仍需在代码规格中逐条锁定：

1. material claim、out_of_world 与 world_scope_gap 的判定 schema；
2. atomic / higher-order unit 的互斥类型规则；
3. explicit/latent rubric 的生成、答案泄漏检查与双人冻结规则；
4. NLI claim entailment、DeepSeek-V4-Lite verifier 与 residual sweep schema；
5. support/contradiction/source-role verdict vocabulary；
6. snippet observation 的日志格式；
7. citation binding 提取格式与 reference-region 规则；
8. ANN/exact probe、来源分层配额与 TEC 饱和和停止规则；
9. discoverability certificate 的查询预算与禁用 oracle token 规则；
10. census/rubric/world-scope gap 仲裁、任务暂停与版本重算流程；

11. judge snapshot、prompt hash 和 fallback 禁令；
12. four-axis equal-weight candidate、门槛/几何聚合与 legacy ablation 的 board naming。

这些是可执行规格。Rubric 已作为第四个内层质量轴加入，不再用 Completeness 代替用户任务履约。

22. 最终判词

旧公式的骨架可以保留，但它只是候选聚合。真正重要的是把四个内层质量构念和 URL 有效性外层定义清楚。

重构后：

- Fact 是报告主动说出的可裁决原子 claims 的事实准确率，不再承担 coverage；
- Evidence 是本次观察证据的 binding precision-coverage；
- Completeness 是 protocol-complete atomic + higher-order unit universe 的分层 coverage；
- Rubric 是用户明确要求和预先冻结潜在研究要求的履约率；
- Provenance 是 URL 存在、规范化和冻结快照有效性的折扣；
- writing Elo 是独立呈现质量。

报告 claim 由高召回候选、NLI 原文蕴含、DeepSeek-V4-Lite 结构复核和残差扫描产生；Fact 再由独立多来源检索、支持/反驳 evidence packet、第二 verifier 与人工抽查裁决。冻结世界外内容不因为 benchmark 缺数据而判错；非物质性内容不奖不罚，物质性缺口触发任务暂停和统一修复。

真正困难的工作不再是调一组小数权重，而是证明 claim 没有系统漏采、TEC 检索接近协议完备、Fact 与 Evidence 输入真正独立、latent rubric 没有答案泄漏，并让每个自动 verdict 都能回到冻结 span 和人工审计记录。

参考资料

- DeepResearch Bench: A Comprehensive Benchmark for Deep Research Agents⁶
- DeepResearch Bench II: Diagnosing Deep Research Agents via Rubrics from Expert Report⁷
- DeepResearchGym: A Free, Automated, and Reproducible Deep Research Agent Training Environment⁸
- ResearcherBench: Evaluating Deep AI Research Systems on the Frontiers of Scientific Inquiry⁹
- LiveResearchBench: A Live Benchmark for User-Centric Deep Research in the Wild¹⁰
- FActScore: Fine-grained Atomic Evaluation of Factual Precision in Long Form Text Generation¹¹
- LongCite: Enabling LLMs to Generate Fine-grained Citations in Long-context QA¹²
- ALiCE: Evaluating Positional Fine-grained Citation Generation¹³

⁶<https://arxiv.org/abs/2506.11763>

⁷<https://arxiv.org/abs/2601.08536>

⁸<https://arxiv.org/abs/2505.19253>

⁹<https://arxiv.org/abs/2507.16280>

¹⁰<https://arxiv.org/abs/2510.14240>

¹¹<https://arxiv.org/abs/2305.14251>

¹²<https://arxiv.org/abs/2409.02897>

¹³<https://arxiv.org/abs/2406.13375>

- LoHoSearch: Benchmarking Long-Horizon Search Agents Beyond the Human Difficulty Ceiling¹⁴
- DRA current implementation: `../deep_research/src/eval/decidable_scorer.py`
- DRA transport evidence: `../deep_research/src/eval/fetch_log.py`
- DRA current design baseline: `DRA_SANDBOX_NATIVE_SCORING_DESIGN_2026-07-17.md`

¹⁴<https://arxiv.org/abs/2606.12837>