

DRA 评测重构

从报告级乘法到沙盒原生证据测试

旧评分为什么不够 · LoHoSearch 给我们的启发 · DRA v3.2 基线 + v3.3 候选修订

长篇 Deep Research

冻结网页沙盒

12 Harness

可审计证据

长版 · 约 90 分钟

刘弈博 · 2026-07-18

一句话结论

DRA 的优势不是 “有一个更聪明的 LLM judge”，而是我们拥有一个有限、冻结、可回放的网页世界。

我们不需要写出一份唯一标准答案，
也不需要抽取全世界所有事实。



我们需要把每一项“研究工作”编译成
可执行、可追溯、允许替代证据的测试。



主分：有本次交付证据完成的必要研究工作占比

今天要回答五个问题

- | | | |
|----|------------------|--|
| 01 | 旧评分为什么不够 | Fact / PoF / Completeness / Provenance 的层级错位 |
| 02 | DRA 真正应该测什么 | 发现、观察、利用、完成；广度与报告质量分离 |
| 03 | LoHoSearch 做对了什么 | 全图轻量结构 + 局部昂贵语义 + 自动与人工验证 |
| 04 | 其他论文提供了哪些积木 | rubric co-design、冻结环境、广度分母、引用审计 |
| 05 | 我们接下来怎么落地 | DRA v3.2 基线 + v3.3 候选修订、验证矩阵、Dev-14 与 56 题扩展 |

DRA 的实验对象：同一世界中的 12 种研究系统

控制变量不是一句口号，而是任务、底模、网页、工具身份与运行证据都被冻结。

统一输入

同一 query
同一公共输出要求
同一任务 manifest
不向 agent 暴露
scorer-shaped 提示

统一世界

冻结 Magento 商城
冻结 Postmill 论坛
离线 Kiwix Wikipedia
统一 URL registry 与
搜索 API

统一比较

12 个 harness
adapter
相同底模与预算协议
运行日志与报告 seal
固定任务集做宏平均

输出不是一个答案

长篇报告需要：

- 多方向检索
- 跨来源比较与机制解释
- 冲突、条件和不确定性
- 面向用户约束的建议
- 就地引用与可复核证据

v3 目标配置

56 道正式任务

Dev-14 校准子集

12 Harness

一个固定文档世界

我们“拥有整个世界”——但只拥有文档世界

可辩护的闭合边界必须比“全知事实表”更精确。

可以穷尽并冻结

- 允许访问的 URL、canonical alias 与 redirect
- 每个 URL 的快照、状态、内容 hash 与结构 span
- 表格、商品字段、论坛 post/reply、页面链接图
- 本次运行真正交付给 agent 的 artifact 与 span
- 固定 compiler 在单题范围生成的语义资产与测试

不能声称穷尽

- 每页中所有可能的自然语言命题
- 所有合理的人类解释与推理路线
- agent 可能生成的无限搜索词
- 所有替代证据组合与未来策略
- 沙盒外现实世界的完整真理

Closed document universe $\neq$ complete semantic universe

Deep Research 不是把 QA 做得更长

任务形态	主要输出	关键难点	DRA 的关系
Fact QA	一个事实 / 短答案	定位并验证	不是
Deep Search	少量难找答案	多跳定位与消歧	相邻能力
Wide Search	大规模实体 / 字段表	枚举、去重、停止	覆盖“广度”的一部分
Deep Research	长篇、结构化、带引用报告	分解、跨源综合、冲突、条件、建议	核心对象

因此不能只问“答案对不对”

底层事实可以做确定性核验，但正式评分对象必须覆盖比较、机制、冲突、跨来源综合、教程、预算方案和推荐。

最开始的做法：三个质量项加权，再乘 Provenance

旧方案抓住了重要信号，但把不同层级的构念压成了一个报告级混合分。

$$Q_{old} = 0.39 \times \text{Fact} + 0.28 \times \text{ProofOfFetch} + 0.33 \times \text{Completeness}$$

$$\text{Truth}_{old} = \text{Provenance} \times Q_{old}$$

Fact

结构化商品事实：主要是价格与 overall rating

ProofOfFetch

报告引用页是否出现在本次抓取集合

Completeness


答案键 vital nuggets / concept / forum slot 覆盖

Provenance

引用 URL 能否由搜索、抓取或已抓页面链接解释

历史候选还讨论过 $\text{Provenance}^{1.5}$ ，但没有独立构念或校准依据。

旧 Provenance 能证明“URL 不是凭空猜的”，但不能证明“说法有证据”



旧规则回答

引用 $URL \in S \cup F \cup L$ 吗？
—— 能解释 URL 从哪里来。

仍然回答不了

- 支持段落真的交付了吗？
- 引用是否就地绑定 claim？
- 页面是否语义支持？
- 来源角色是否适合该推断？

URL 可解释 $\neq$ 引用支持 $\neq$ 证据完成

问题一：Fact 检查得很确定，但测到的不是“研究完成度”

Fact 实际检查什么

1. 识别商品实体
2. 抽取价格或 overall rating
3. 在 ± 40 字符窗口绑定实体
4. 对照商城 DB truth
5. 检查同句商品 citation
6. 计算 $\text{precision} \times \text{recall volume}$

它的确定性优势

- 数值可复现
- 型号绑定可审计
- 相似变体不共享事实
- 可作为具体 check 的 verifier

为什么固定 0.39 不合理

- 很多题没有足够可比数值
- 技术机制、耐久、冲突与取舍没有进入
- “无可检查 claim” 直接为 0
- 写对外围价格可能掩盖核心研究缺失
- 字段多的题天然获得更多奖励机会

裁决：保留 deterministic parser，但把它下沉为 research check 的执行器。

问题二：抓取过页面，不等于模型看到了支持内容，更不等于正确使用



旧 ProofOfFetch 大致停在这里

DRA 真正需要证据门覆盖的区间

根本问题

把 PoF 作为独立加分项，会奖励“抓了但没用”；而“写对了但没看证据”又可能被其他质量项补回来。

问题三：Completeness 容易把“答案键覆盖”变成“复现出题者路线”



Known witness 只应证明“可答” · 不应成为 URL allowlist

问题四：报告级乘法把局部证据错误“平均掉”，任意权重又难以解释

$$\text{Truth_old} = \text{Provenance} \times (0.39F + 0.28\text{PoF} + 0.33C)$$

关键推荐无证据

只让整体 provenance 小幅下降；其余段落仍可能把总分拉高

抓了很多无关页

PoF 仍可能得分，却没有完成任何研究要求

文风与引用光环

Quality judge 或 completeness 已奖励“像报告”，再乘 grounding 可能重复计分

权重 / 指数敏感

0.39/0.28/0.33 与 ^1.5 不能从构念自然推导，换参数可能翻榜

证据门应该放在每个可验证研究要求内部，而不是整篇报告末尾。

一个真实 pilot 暴露了问题：0 分不等于“完全没做”

同一份音频购买报告，用三种视角得到完全不同的诊断。

旧固定路线评分



0 / 15

内容完成度



5 / 9 · 55.6%

有证据完成度



1 / 9 · 11.1%

报告确实做了

设计、IPX7、电池、Hi-Res 等 5 个必要方向

但证据很弱

只有 Ortizan 商品页同时满足内容、引用、观察与支持

核心诊断

旧 0/15 同时混入“没走预设路线”和“证据不足”

替代方案必须同时满足八个约束

不是“加一个更强 judge”就能解决。

自动化高

不为每题从零写复杂答案 rubric

可复现

固定 world / compiler / matcher /
judge / scorer 版本

同一程序

12 个 harness 使用同一语义，不
按工具名特判

证据可审计

URL、交付 span、绑定、支持、来
源角色可下钻

广度有分母

从 query facets 编译，不用 URL
数或篇幅代替

不绑路线

新在册证据满足合同即可通过

排名简单

一个主分能一句话解释，不重新发明
复合指数

边界诚实

不声称穷尽全部语义或覆盖未来所有
策略

目标：测“有证据地覆盖了多少必要研究工作”，并把 URL 造假独立、强制地暴露出来

02

DRA 真正应该怎样评

把 Deep Research 拆成发现 → 观察 → 利用 → 完成；广度有分母，质量有独立面板。

一条研究结论要经过四个阶段



Deep Research 的“广度”必须由 query 定义分母

错误的广度代理

- 访问 URL 数
- 搜索次数
- 引用数量
- 报告字数
- 事实原子数量

这些都能被重复页、无关页、冗长写作或字段密度刷高。



正确的分母：query facets → research units → checks

技术与营销

识别主张 · 解释机制 · 说明不能推出什么

用户场景

噪声 / 预算 / 空间约束 · 条件差异 · 风险边界

方案比较

共同维度 · 跨页对齐 · 冲突处理

推荐与行动

多个可行方案 · 取舍理由 · 可执行建议

广度 = 在平级用户研究方向上，完成了多少可执行检查

评分对象的层级：事实是证据，研究工作才是一分

例：审核“Hi-Res 蓝牙”宣传

Atom：商品页是否写 Hi-Res

Checks：

1. 准确转述主张
2. 用机制 / 条件解释能推出什么
3. 说明不能推出什么
4. 连接到用户决策

Unit：完成一次技术宣传审核

Facet：技术与营销

Evidence atom

网页里一个规格、主张、机制说明或用户体验事件

Research check

对报告局部能力的可执行检查；内容合同 + 证据合同

Research unit

用户可感知的一项完整调研工作：比较、审核、教程、推荐

Research facet

平衡用户的多个研究方向，防止事实数量决定权重

链接真实性没有被取消：先分清“虚构”、“越界”与“基准错误”

失败类型	判定	含义	主分处理
nonexistent_fabrication	URL 在 canonicalize / alias / redirect 盲复核后确认不存在	真正的虚构引用	对应 check 失败；整道 task 清零
off_world_citation	URL 真实，但不属于冻结 registry / snapshot	越出评测世界，不能据此证明本次调研	引用无资格；check 失败；独立 protocol flag
canonicalization_or_registry_err or	URL 真实且应在世界内，但 alias / redirect / registry 漏记	benchmark 仪器错误，不是 harness 造假	暂停裁决；修复后全体同 epoch 重算
malformed_citation	引用格式或拼写有误，但可唯一恢复目标	呈现 / 格式违约，不自动等同虚构	按公开 canonicalization 规则裁决；记独立 flag

registry membership 可以判“是否属于冻结世界”，但不能单独判“现实互联网上是否存在”。

URL 真实也不够：证据必须本次交付、就地绑定并真的支持

失败类型	判定	含义	处理
unobserved_citation	URL 存在，但支持 span 本次未交付	可能靠参数知识或事后补引用	对应 check 失败
unsupported_citation	页面已交付，但不支持附近说法	主题相关不等于证据支持	对应 check 失败
wrong_binding	页面可能支持，但引用没有绑定对应 claim	读者无法知道引用支撑哪句话	对应 check 失败
contradicted_citation	页面实际反驳报告	方向性事实错误	check 失败；决定性结论记 critical
source_role_misuse	来源角色不满足合同	营销主张被冒充独立测量等	对应 check 失败

不一票否决整题
这些默认只使对应 check 失败；决定性反驳另记 critical error。

可下钻
每个 verdict 必须指向 report span、evidence span、delivery record 和合同前提。

报告质量要评，但不能再乘回主分

“有没有完成”由 Research Test Suite 判断；“完成得怎样”由独立质量面板判断。

Synthesis

多份证据是否组织成连贯比较、机制或因果链



Uncertainty & Conflict

是否诚实表达条件、冲突、证据强弱与未知



Decision / User Utility

是否回应预算、场景、风险、步骤与取舍



Presentation

结构、连贯、简洁、可读、引用呈现自然



评法

同题、同轴、匿名两两比较；位置交换；固定 anchor reports ；遮蔽 harness 与 DRA-GRC 。

榜单角色

单独展示四轴与人工校准；不合成 Overall ，不用成本或质量面板偷偷破同分。

03

美团 LoHoSearch：全量世界如何真正被利用

详细拆解：全图轻量建模、局部子图采样、自然语言化、唯一性检查、难度过滤与人工审核。

LoHoSearch 一页概览

这是一套长时程 Search Agent 基准，不是长篇 Deep Research 报告基准。

论文与目标

LoHoSearch: Benchmarking Long-Horizon Search Agents Beyond the Human Difficulty Ceiling

美团团队
2026-06-11 提交； v2 2026-06-17

目标：用全局图统计系统性提高单题搜索空间和结构复杂度。

7.62M

Wikipedia 实体节点

265M

正文有向超链接

544

人工复核问题

11

主题领域

34.74%

最强系统准确率

61

正确轨迹平均工具调用

+6.8


DeepSeek-V4-Flash 上下文实验绝对增益

对 DRA 最重要的启发

“全量”只做便宜、稳定、可复现的结构；昂贵语义生成、验证和人工审核只发生在采样局部。

LoHoSearch 的出发点：作者将快速饱和归因于人工缺少全局统计视角

BrowseCompn 在十个月内快速饱和



论文 Figure 1

原因：人没有全局统计视角

人工更容易选择熟悉、流行、直接相连的实体；约束数量和候选空间难以系统控制。

两条难度轴

- ① 单个约束的搜索空间
候选越多，验证与排除越长。
- ② 结构复杂度
多个约束必须联合满足，图中循环与交叉约束难以分解。

LoHoSearch 的完整数据构建流水线

四阶段：知识图谱构建 → 子图采样 → QA 生成与验证 → 后过滤与人工审核。





Figure 2: Overview of the LoHoSearch pipeline.

阶段一：全量遍历 Wikipedia ， 但只构建廉价结构图



7.62M

nodes

265M


directed edges

这一步没有做什么

- 没有让 LLM 为 762 万页面抽取“全部事实”
- 没有在全库生成自然语言关系描述
- 没有在全库尝试每种问题或答案路线
- 没有以图谱为现实世界完整真理

全量成本 $\approx$ 解析 + 链接 + 类型 + 统计

阶段二 A：树结构用“交集唯一 + 删除不唯一”保证约束必要




$$\bigcap_1^N S_i = \{\text{root}\} \quad \text{但} \quad \bigcap_{j \neq i} S_j > 1$$

默认参数与三条约束

- $N = 3$ 个一级关系；每个中间实体最多 $M = 2$ 个二级关系； $\tau = 3$
- 每个关系的候选搜索空间 $|S| > \tau$
- 任意删除一个一级关系，剩余候选交集仍 > 1 —— 每条关系都必要
- 全部 N 个关系的候选交集恰为 $\{\text{root}\}$ —— 图内答案唯一
- 二级 pseudo-candidate 不能与其他中间实体组合出另一个唯一答案

阶段二 B：图结构用循环与交叉约束提高不可分解性



树：大候选空间 · 图：大候选空间 + 循环 / 交叉约束

采样

1. 选低流行度 seed（答案）
2. 贪心扩展到最多 10 个实体
3. 优先与当前子图连边最多、关系搜索空间最大的候选
4. 要求类型多样、边数充分、整体连通


唯一性与抗捷径

- 在完整图上穷举回溯，寻找满足相同类型和有向邻接的替代实体集合
- 找不到替代才确认图级唯一
- 还要求 seed 有足够同类型混淆候选，避免只靠类型枚举暴力解题

阶段三：图结构不是直接交给 agent ，必须转成自然、难检索的问题



阶段四：自动流水线之后，仍需要多 agent 过滤与专业人工审核




必须诚实报告的 29.2%

人工没有找到替代答案，但也无法完全排除；“未发现替代”不是“证明唯一”。

LoHoSearch 的结果：难点不只是“多跳”，而是更长轨迹与上下文管理

正确轨迹工具调用分布（论文 Figure 4）



准确率

GPT-5.5 : 34.74%

DeepSeek-V4-Pro : 15.99%

轨迹长度

BrowseComp : mean 35 / median 26

LoHoSearch : mean 61 / median 59

平均工具调用增加 74%

结构复杂度

DeepSeek-V4-Flash : 树题 11.89%

图题 8.01%

上下文策略

最佳组合只带来 +6.8 个百分点。

LoHoSearch 证明了什么，也没有证明什么

可以借鉴

- 全量轻量结构索引可以系统控制数据构建
- 先采样结构，再做局部语义生成与验证
- 删除测试与全图回溯可以校验必要性 / 唯一性
- 自动生成必须配多 agent 过滤与人工审核
- 公开编辑率、拒绝率和无法证明的边界

不能照搬

- 它没有做全 Wikipedia 的开放式事实抽取
- 唯一实体答案 $\neq$ 多 facet 长篇研究报告
- 图内唯一性不能排除图外 / 现实世界替代答案
- 29.2% 只是“未找到替代”，不是形式化唯一证明
- 难度过滤依赖单一校准模型，可能有家族偏差

借工程分层原则，不借“唯一答案路线”目标

从 LoHoSearch 到 DRA：同一分层原则，不同评分对象

LoHoSearch

全量层

Wikipedia nodes / hyperlinks / P31 / indegree

局部层

采样子图关系描述与自然语言问题

构造目标

大候选空间 + 高结构复杂度 + 图内唯一答案

评分对象

最终实体答案 accuracy

DRA v3.2

全量层

所有沙盒 URL / span / table / link / structured field

局部层

单题事实、经验、机制、冲突、source role

构造目标

多 facet research shape + 可答性 + 不绑路线

评分对象

有本次交付证据的研究覆盖 DRA-GRC

全量廉价结构化 → 局部昂贵语义处理 → 自动与人工验证

04

其他工作提供了哪些“积木”

没有一篇论文直接给出完整答案；我们需要组合 evidence-first 构题、广度分母、冻结环境、引用审计与长报告质量。

Evidence-first 共构：DEEPRUBRIC 与 QUBRIC

DEEPRUBRIC

先采样 seed topic，递归扩展 evidence-backed sub-questions，形成 evidence tree；叶子是原子、可验证评价目标。随后从树反向生成 query 与 rubric，使“题目问什么”和“奖励什么”同源。

9K query-rubric supervision；以约 13× 更少 RL GPU-hours 达到可比结果。

QUBRIC

指出结构瓶颈：开放 query 产生模糊 rubric；粗暴收窄 query 又会引入无法验证的虚构参考。

通过 teacher key points、query-rubric co-design、contrastive criteria 与 learnability filtering，保留真正有区分度的训练样本。

DRA 的取舍

接受“证据结构与 query / tests 同源”，但把 witness 降级为可答性证书；用合同接受新证据，避免训练式 rubric 绑定构题路线。

广度类基准告诉我们：必须同时报告连续覆盖与严格成功

WideSearch

200 道人工题；收集大规模原子信息；最强整体 success 约 5%

对 DRA 的启发：
显式集合分母 + strict success

DeepSearchQA

900 个多步任务；要求穷尽答案列表；强调去重、实体解析、停止条件

对 DRA 的启发：
高 recall 与 precision 的张力

DeepWideSearch

220 题、15 领域；同一任务同时要求多跳深度和大规模宽度

对 DRA 的启发：
深度 / 宽度应分解诊断

DRA：连续 DRA-GRC 做主排序 + Full Pass / Task Solve Rate 单独报告

冻结环境解决“可复现”，但不会自动解决“怎样评分报告”

工作	冻结方式	主要评分 / 分析	DRA 借鉴与边界
DeepResearchGym	ClueWeb22 + FineWeb 稳定搜索 API	信息需求、 retrieval faithfulness 、 report quality	冻结检索可行；语义 ground truth 仍按题构建
FutureSearch DRB / RetroSearch	冻结大量历史网页	人工解题答案 + 长轨迹自动分析	证明 offline 与 live agent 可比；缺少 delivered-span audit
BrowseComp-Plus	固定支持文档 + hard negatives	答案、检索、引用、上下文工程	支持受控消融； gold documents 可能绑定证据路线

结论

“有冻结语料”只是必要条件； DRA 额外利用 Observation Ledger 判断原页面内容经过 harness 变换后是否真正交付。

长报告 rubric 路线：表达力强，但构建成本与路线继承风险都很高

Mind2Web 2

130 个真实长时程 web 任务，投入超过 1,000 人时；用 tree-structured rubrics 构建 task-specific judge agents，同时评价 answer correctness 与 source attribution。

优势：贴近真实 agentic search。

代价：高人力；开放网络答案随时间变化。

DeepResearch Bench II

132 个 grounded research tasks，22 个领域，共 9,430 个细粒度二值 rubrics；覆盖 information recall、analysis、presentation。

rubrics 来自专家调查文章，经四阶段 LLM+human 管线和 400+ 专家人时。

DRA 的选择

不用粗粒度 Likert，也不为每题写庞大唯一答案 rubric；由统一 compiler 生成少量分层 tests，并公开人审编辑率与异常率。

引用研究告诉我们：正确、完整、真实依赖是三件不同的事

ALCE

分别评 fluency、answer correctness、citation correctness / completeness；引用质量可自动化，但仍主要是 claim 级。

FActScore

把长文本拆成 atomic facts，计算有可靠来源支持的比例；精确度强，但分母来自报告自己说了什么。

Correctness is not Faithfulness

引用页支持说法，并不保证模型真的依赖该页；研究发现 post-rationalization，最多 57% 引用缺乏 faithfulness。

DRA 的增量

registry + delivered-span ledger 排除“未观察引用”；8-10 道反事实双胞胎世界再抽样检查结论是否随证据改变。

在本次核查的代表性工作中，五项能力通常被分开处理


方法	冻结世界	广度分母	运行内交付	替代证据	长报告综合
LoHoSearch	●	结构约束	—	图条件等价	—
DEEPRUBRIC / QUBRIC	局部证据	rubric	—	rubric 条件化	训练侧
Wide / DeepSearchQA	开放网	答案集	—	答案集等价	聚合为主
DeepResearchGym	●	key points	事后 claim-citation	引用 URL	报告 rubric
BrowseComp-Plus	●	答案	gold-document 核验	gold documents	答案为主
Mind2Web 2 / DRB II	开放网 / 专家文	rubric	轨迹 / 引用接口	rubric 接受	报告 rubric
ALCE / FActScore	检索语料	report claims	—	任意支持源	claim-level
DRA 候选目标	●	query facets	● span-level	● contract	独立质量面板

● = 正式设计目标；“—”表示论文不以该构念为核心。矩阵用于定位，不表示优劣总评。

可验证的设计机会：这些现在还是 hypotheses ，不是已证明贡献

Gap 1

广度与证据常被分开评



DRA 在每个 research check 内把内容完成与证据门合取。

Gap 2

固定 gold URL 容易绑路线



证据合同定义认识论要求，known witness 只证可答；新在册证据可按同一 matcher 通过。

Gap 3


“抓取过”通常停在工具事件



Observation Ledger v2 保存 raw → transforms → delivered artifact 血统。

Gap 4

引用正确不等于证据依赖



反事实双胞胎世界与 canary 作为独立因果接地证书。

Gap 5

自动 rubric 很难证明有效




Dev-14 + 自然 / 腐蚀 / 替代 / 边界四层校准，公开 FRR/FAR 与人工编辑率。

05

DRA 沙盒原生评分： v3.2 基线 + v3.3 候选修订

World Index → Task World Model → Research Test Suite → Execution Audit ; Raw coverage 与 integrity-adjusted ranking 分开。

整体架构：三层资产 + 一层运行审计



输出： Penalized mean DRA-GRC + Full Pass / URL / Funnel / Quality / Cost / Counterfactual

Layer 1：World Index 全量做什么

约 23 万页面可以全量结构化，但不做每页“所有事实”的 LLM 枚举。

1 URL canonicalization / alias / redirect

2 HTTP 状态、快照、内容 hash 与 manifest

3 正文 section / paragraph / list 的稳定 span

4 表格 header-row-column-cell 关系

5 论坛 post / reply / quote / author 层级

6 页面与 span 级出链图

7 JSON-LD、商品规格与确定性结构字段

8 source family + exact / BM25 / dense 检索

9 exact duplicate 与 near-duplicate clusters

成本原则

全量只做线性解析 / 索引；小规模可枚举的高风险规则 / 域名全审，其余按 source family×parser×template 分层抽样；进入 TWM core witness 或高复用 certificate 的 span 全审。

Layer 2：只在单题候选区域做昂贵语义抽取

商品页

规格值 / 原值
厂商与零售主张
限定条件 / 版本 / 时间
“没有写”只允许有界范围

论坛与社区

同型号 / 相似型号
事件与场景条件
使用时长 / 时间
个案不能升级为发生率

Wikipedia / 标准 / 技术页

机制 / 定义 / 测量方法
适用条件
一般机制到具体商品必须有 bridge
不把百科当产品实测

抽取结果不是“真 / 假”一列，而是：谁在什么时间、什么条件、以什么来源角色说了什么；以及支持、冲突、限定、异质、unknown 的关系。

Layer 3：从 query 编译研究结构，不是随机从事实池抽题

- 1 Query / Case Blueprint** → 用户约束 · 候选范围 · facets · 输出需求
- 2 Task Contract** → 显式需求 · 隐含不可删除义务 · 条件与禁止推断
- 3 Research Units** → 比较 · claim audit · 机制 · 冲突 · 教程 · 预算 · 推荐
- 4 Executable Checks** → 每 unit 2-5 个 canonical checks
- 5 Frozen RTS** → content contract · evidence contract · premise DAG · witnesses

Route S · 前 14 道人工 seed

query-first 恢复 facets；双人抽样审核必要性与自然性。

Route G · 后续生成题

先选 research shape 和 blueprint，再共同生成 query / RTS。

必须诚实：Compiler 产生的分母仍是“待验证假设”

不是什么

不是世界自动吐出的客观真理，也不是 LLM 生成后就冻结。

谁来提案

Compiler 从 query、任务类型学和 TWM 提出 facets / units / checks 。

谁判必要

双人盲标 + deletion test：删掉它是否实质改变用户任务？

谁证可答

冻结世界中的 evidence contract + 至少一组 known witness；不将 witness 当唯一路线。

谁验区分度

oracle / null / 流畅空话 / URL dump / 合法替代 / 无效路线。

能声称的是“经校准的 query-conditioned 分母”，不是“唯一客观 rubric”

单题编译例：\$60 阳台 / 泳池扬声器决策

任务并不要求一个固定胜者，它要求审计 Soundcore Flare 2 与 Ortizan 40W 的可证性。

Facet / Unit	核心 check（节选）	证据合同 / 分支
价格与候选	对齐两个 listing 的精确价格，确认是否满足 \$60 总预算	两个商品页；版本 / 时点一致
输出与失真	准确转述 watt / THD 文案；不把 <1% THD+N 直推成 “高音量更低失真”	listing + 测量 / 机制页；禁止过度推断
泳池场景	解释 IPX7 的测试边界；分开标准含义、商品声明和用户个案	角色合同：标准 / 技术 + listing ；论坛不可替代认证

前三个 units 展示一个重要原则：不能把不同版本、时点或条件的有利前提拼接成合法路线。

单题编译例（续）：条件分支和推荐包络避免固定路线

Facet / Unit	核心 check（节选）	证据合同 / 分支
Hi-Res 宣传	若两个 listing 均无该宣传，报告有界说明后可判“不影响决策”	absence branch OR claim-audit branch；不强制 LDAC 路线
社区证据	区分一般扬声器讨论与同型号涉水验证；可报告有界未找到	任意合格论坛页 OR bounded absence protocol
推荐	任一候选都可通过，但必须与预算、审计性、失真风险和未知项一致	Decision Envelope；不固定 soundcore_flare2

允许多路线

新 URL、有界未发现、独立测量页都可在同一契约下裁决。

允许多结论

推荐不锁定商品名；只要它属于约束与证据一致的 Decision Envelope。

不设唯一标准路线：冻结的是证据合同，不是 URL 白名单

$$A_u = \{ E \subseteq W : E \models \Gamma_u \} \quad \text{known witnesses } K_u \subset A_u$$

Γ_u ：证据合同

规定：

- 哪些外部前提必须支持
- 允许何种来源角色
- 单页还是多页联合
- 条件与范围如何绑定
- 哪些推断被禁止

OR of AND 路线

同一前提可有多多个 evidence bundles：

(bundle A：商品页 + 技术页)
OR
(bundle B：独立测量页)

每个 bundle 内是 AND；bundles 之间是 OR。

运行时新页面如何通过

1. URL 属于冻结 registry
2. 支持 span 本次交付
3. 与附近 claim 正确绑定
4. 语义满足合同前提
5. source role / scope 合格

收集为 novel pair，在同一榜单 epoch 内批量盲裁。

若当前只知道一个支持页面，诚实标记 `single_source`；不虚构“所有命题都有多路线”。

替代证据不能“边跑边改榜”：用 leaderboard epoch 冻结 certificate ledger



Layer 4 : Observation Ledger v2 统一 12 个 harness 的“观察”语义



最小评分单元：Content Contract × Evidence Gate

$$Z_{t,f,u,k} = C_{t,f,u,k} \times E_{t,f,u,k}$$

C：内容合同

报告是否真的完成这个 check：

- 提到要求的对象 / 维度
- 做出比较或解释
- 正确表达条件与范围
- 把结论连接到用户需求

由 typed pointwise judge / deterministic executor 判定。

E：证据门



Valid in registry

×




Observed / delivered

×



Bound locally

×



Semantically supportive

×



Role compatible

$$E_k = X_k \cdot \max_{r \in R_k} [\text{Coherent}(r) \cdot \prod_p \prod_{e \in r(p)} V_e O_e B_{e,p} S_{e,p} R_{e,p}]$$

Coherent(r)：型号 / 版本 / 时间 / 条件 / scope 一致 · X_k ：冻结的 material conflicts 已被观察并处理

部分完成来自一个 unit 的 2-5 个 checks 通过了多少，而不是 judge 随意给 0.5。

层级宏平均：等权是默认规则，不是“无权重”



$$\text{Raw GRC}_t = \text{weighted-mean_facets} \left(\text{weighted-mean_units} \left(\sum_k m_k z_k / \sum_k m_k \right) \right)$$

同一个技术主张，如何从报告句子一路得到任务分

失败路线

报告：“<1% THD+N 证明它在高音量下失真更低。”

C=1：确实做了失真比较
V=1, O=1, B=1, R=1；S=0：页面没有音量 / 频率 / 测试条件
⇒ z=0 （unsupported over-inference）

合法路线

报告：“listing 标称 <1% THD+N，但未给出音量、频率与测试设置，不足以比较高音量失真。”

C=1；listing + 测量解释页组成 coherent route
V=O=B=S=R=1，且未忽略 material conflict
⇒ z=1

单题结果（当前 pilot 的人工校准记录）	数值	含义
ContentBreadth	5 / 9 = 55.6%	九个必要检查中，内容讨论到五个
Raw grounded coverage	1 / 9 = 11.1%	只有一个同时满足内容与证据门
Full Pass	0	并非“完成”这道调研任务
Integrity-adjusted	11.1% 或 0	无确认不存在 URL 时为 11.1%；若有则当题为 0

这个示例是方法闭环记录，非正式榜单分；自动裁判校准未过前标记 formal_eligible=false。

最终每道题同时给出三个直觉量

ContentBreadth

只看 C：
报告讨论到了多少必要研究检查？

可识别“写到了但没证据”。

Raw DRA-GRC

看 $z = C \times E$ ：
有本次交付、就地绑定且支持的证据
完成了多少研究工作？

这才是 grounded research
coverage 构念分。

Full Pass

所有 core checks 通过 + 输出合同满足 + 无 critical error + 无 confirmed nonexistent citation。

Task Solve Rate = 完整通过任务 / 固定正式任务。

$$\text{UnsupportedBreadthGap} = \text{ContentBreadth} - \text{DRA-GRC}$$

链接“真实性”与“冻结世界合规”分开处理

$G_t \text{ official} = 0$ if confirmed nonexistent_fabrication; otherwise $G_t \text{ official} = G_t \text{ pre}$

Lane A · 确认不存在的 URL

1. canonicalize 并查 alias / redirect
2. 排除 registry 缺失与 benchmark 错误
3. 盲复核确认 URL 不存在
4. 当题 GRC 清零, 记 nonexistent-fabrication event

Lane B · 真实但 off-world 的 URL

1. URL 在开放网可能真实
2. 但不属于冻结 registry / snapshot
3. 无法证明本次 sandbox 内调研; 证据无资格
4. 对应 check 失败 + off-world protocol flag

敏感性分析

同时报告“off-world 仅使证据失效”与“off-world 也任务清零”两种排名。

主表强制展示

$\text{nonexistent-fabrication rate} \cdot \text{off-world rate} \cdot \text{affected-task rate} \cdot \text{clean-run rate} \cdot \text{CI}$ 。

Research Quality Panel 的操作化：只比较“怎么写”，不重复判事实

输入

同一道 query 的两份匿名报告；状态遮蔽的 evidence packet

单位

一次只问一个轴：Synthesis / Conflict / Utility / Presentation

防偏

A/B 位置交换；矛盾 pair 标 unstable；固定长报告分段协议

标尺

固定 anchor reports + 固定配对图；可估 anchored Bradley-Terry 轴向分

校准

pilot 每轴 ≥ 200 对、3 名标注者；最终 n 由 power/MDE 决定；报 κ/α 与偏差

榜单

四轴另表 / 雷达图；不合成 Overall，不进入 tie-break

主榜回答“有证据完成了多少” · 面板回答“完成得是否清楚、诚实、有用”

最后榜单长什么样：一个排名分 + 强制完整性列

Rank	Harness	Integrity-adjusted GRC ↑ (95% CI)	Raw GRC ↑	Task Solve ↑	Eligible
1	Harness A	0.63 [0.57, 0.69]	0.63	0.18	Yes
2	Harness B	0.55 [0.49, 0.61]	0.61	0.11	Yes

任务下钻

facet / unit / check 通过率
ContentBreadth 与 gap
失败类型与实际证据路线

引用面板

nonexistent / off-world /
unobserved / unsupported / wrong-
binding / contradicted
affected-task / clean-run / 引用数相
关性

过程漏斗

SearchExposed → Delivered →
UtilizedDelivered → VerifiedPass

质量与效率

四轴质量面板
页面 / token / 时间 / 成本
反事实审计证书

若 DRA-GRC 差异落入预注册等效区间：宣布并列，不用质量或成本偷偷破同分。

验证门 I：先证明分数不可被捷径骗取，世界与分母可重现

Gate A · Scoring invariants

V1-V10

oracle ceiling · null floor · URL/fact dump · fluent unsupported · valid/invalid route · unobserved injection · local corruption · monotonicity · granularity invariance

Gate B · World / Compiler

V11-V19

World Index determinism · candidate saturation · assertion/role/conflict · query round-trip · test necessity · answerability · held-out probes

门与门不能相互抵消

oracle 通过不能抵消合法替代路线误拒；World Index 可重建不能抵消 compiler 分母错误。

验证门 II：再证明运行仪器可接受，主分对人类调研广度有效

Gate C · Execution acceptance

V20-V22

12 adapter observation normalization · delivery canary · runner/matcher/judge 人工盲标 · route FRR/FAR with confidence bounds

Gate D · Benchmark validity

V23-V30

盲专家 grounded-breadth （不看 RTS/ 分数） · old-vs-new validity · counterfactual · reproducibility · repair · gaming · integrity · capacity

校准样本量

1,500-2,500 判定对是 pilot target；最终 n 按 power/MDE；稀疏层只报 CI。

独立效度

专家只看 query、report 和可访问引用；不看 RTS、check pass 或 DRA 分数。

06

后续实施路线

先证明一道题的方法闭环，再扩到三类任务、Dev-14 和 56 题；发布门不过，不发榜。

Query 构建保留两条路：自然种子与世界反向生成分层报告

Route S · Seed / query-first （前 14 题）

1. 保留人手写的自然用户问题
2. 标注者只看 query，独立恢复用户约束、facets 和不可删除的研究工作
3. 再从冻结世界建 TWM，审计每项是否可答 / 可达
4. Compiler 只提出 tests，人工记录 merge / split / delete
5. 不因为某个 harness 没做到就改 query 义务

Route G · Generated / world-first （剩余 42 题）

1. 预先选 research shape，而不是随机抽几个事实
2. 从 World Index 选候选对象、用户约束和来源角色
3. 建立局部 evidence subgraph / TWM，验证冲突、路线多样性和可答性
4. 先编译 RTS，再隐藏实体细节、URL 和 witness route
5. 生成自然 query，使用 round-trip 检查没有漏需求 / 泄答案

主表整体排名，但必须同时分层报告 Route S 与 Route G，避免 42 道生成题淹没自然种子集的行为差异。

Route G 的真实生成逻辑：先定研究形状，再隐藏证据路线生成 query

Research Shape

比较 / 机制 / 冲突 / 决策
需要哪些 source roles ?

Case Blueprint

候选行动 A
用户约束 U
优先级 / 硬约束

Evidence Subgraph

商品主张 / 机制
社区事件 / 冲突
页面 + support spans

TWM + RTS

可答性
必要性
合法替代路线
禁止推断

Hidden View → Query

隐藏 URL / witness / 参考
结论
保留用户需求
自然化 + round-trip

不能做

随机抽 E1-E4 就让 LLM 编一个故事。

必须检查

隐藏任一 core obligation 后，query 是否仍忠实并需多分支调研。

不泄漏

agent 只看 query 和公共输出合同，不看评分步骤、索引 URL 和参考推荐。

Phase 0-3：把“方法”先做成一道可重放的工程样本

P0 · 冻结现状

保留旧公式、56 道 query、registry / graph / result 哈希、12 个 adapter 版本。
交付：baseline manifest + 不可变的对照表。

P1 · World Index

全库轻量结构化：URL、页面类型、标题、链接、段落、商品 / 概念实体、来源角色和可达性。
门：确定性重建 + 抽样解析正确率。

P2 · 单题 TWM

以 dra_v3_dev_audio_0002 生成 Task World Model：候选页、事实簇、冲突、证据角色、可接受结论包络。
门：专家能从写明为何每个 core check 可答。

P3 · Compiler + Matcher

从 query + TWM 编译 facet / unit / check；支持未预选页面的 on-demand 证据匹配。
门：合法替代路线通过，无效路线失败。

成功标志：同一份报告 → 同一 observation ledger → 同一证据判定 → 同一分数证书

搜索 API 是共享的实验仪器：“所有 harness 都用它” 只证公平，不证有效

Model precision

精确型号 query 返回目标型号 / 兼容别名的比例

Source coverage

商品 / 论坛 / 技术 / Wikipedia 各来源的可达覆盖

Oracle recall@k

对每题的 known witness 和 held-out admissible evidence，搜索前 k 位能否触及

Pollution rate

与型号 / 技术概念无关页的比例；按 source family 分层

Determinism

同 query + API version + snapshot 是否产生相同候选集和排序

Latency / failure

p50 / p95 延迟、超时、空结果、来源给额失败


分责记录

漏斗中分开 API 未暴露 / agent 未点击 / 抓取失败 / 已交付未使用。

冻结与回归

发布 search API version + relevance test suite + 每次改动前后的证书。

别人拿到 DRA ，新 harness 应该如何使用



Phase 4-7：统一观测协议，然后校准编译器和裁判器

阶段	核心产物	必过验收	不过时怎么办
P4	12 harness 统一 Observation Protocol v2	search / fetch / browser / subagent / cache 的事件规范化；令牌传递正确	该 adapter 标记 ineligible，不用报告文字倒推观测
P5	runner + evidence certificate + replay CLI	四份参考报告与局部腐蚀版满足单调性和局部性	回到单题修 matcher / runner，不扩题
P6	Dev-14 双人盲标与 adjudication	编译器恢复的必要要求与人类带一致性和可答性证书	修改类型学 / 编译规则，不手工掩盖
P7	pilot 1,500-2,500 个判定对	自然 / 伪证据 / 合法替代 / 边界四层；最终 n 按 power/MDE；稀疏层只报 CI	确定性下沉或加入 PENDING 队列；发布前 PENDING=0
一致性 报 κ / Krippendorff's α + 分歧类型 准确性 不只看 agreement；看 FRR / FAR / macro-F1 / CI 偏差 检查路线、长度、文风、位置和 harness-family 偏差			

Phase 8–10：扩题、因果审计、冻结发布

P8·56 题扩展

Route S：14 道手工种子，用于可解释的编译校准。
Route G：剩余 42 题从任务世界和类型模板编译。
按主题、任务形态、来源角色、难度分层；每题先过 answerability + necessity + shortcut test。

P9·抽样因果审计

选 8–10 道 pivotal 题构造 W' ：修改决定性事实、保留界面和工具协议。
重跑 harness，检查报告中的相关结论是否跟着世界改变。
作为 Causal Grounding 独立证书，不与主分相加。

P10·冻结与发布

同时冻结 world snapshot、index、TWM、RTS、matcher、judge、scorer、adapter 和提交协议。
现有 12 harness 只用于特征化与攻击面发现，不反向优化正式题。
改动走 erratum / challenger / 新版本，不静默改分。

关键分界：评测集必须覆盖“合法证据空间”，但不能根据 12 个现有 harness 的路线定制正式答案。

把论文最小闭环、正式 benchmark 和增强审计分开

A · 论文最小闭环

一题端到端工程样本
三类 DR 任务 MVP
Dev-14 compiler / matcher / judge 校准
新旧分与盲专家广度判断的效度对照

B · 正式 Benchmark Gate

56 题 Route S / G 分层
Search API 质量证书
12 adapter 资格与 report-only 轨
certificate epoch + PENDING=0 + 全部
ReleaseGates

C · 增强研究轨

8-10 道 twin-world 因果审计
Decision Envelope 更完整形式化
四轴质量面板的大规模定标
跨版本 challenger / canary / 长期监控

只有 A 是当前方法论必需；B 是对外发榜必需；C 是可独立发展的增强贡献，不应阻塞最小论文闭环。

Dev-14 不是“手写 14 份标准答案”，而是标定测量过程

1

双人盲拆 query

独立标注用户约束、不可省略的研究方向和可选项

2

对照 Compiler

只做 merge / split / delete / necessity 判定；记录所有人工修改

3

Evidence audit

确认冻结世界中至少一条合法支持组合；必须允许替代页面

4

删除 / 捷径测试

删除 check 是否改变任务实质？只倒 URL 或写流畅空话能否骗分？

5

独立裁决

测人际带、编译器编辑率、分歧、用时与可重现性

人类标注的作用：为 Compiler / Matcher / Judge 建立效度证据，不是为每道题规定唯一路线

56 题扩展：不再用“主题 × 随机原型”就直接入榜

事实 / 规格

比较 / 排序

宣传审核

机制解释

冲突处理

跨来源综合

决策 / 推荐

有界缺失

耐用 / 社区经验

教程 / 行动计划

演化 / 变化

跨页聚合

Route S · 14

前 14 道种子题
人类可解释地校准类型学与编译器

Route G · 42

由冻结世界 + 任务类型生成
反向编译 query + tests，过滤后才入集

Held-out

保留未参与调试的路线、文风和 harness-family
输出
用于测 route binding 和过拟合

入集条件：Query round-trip 通过 ∧ Core checks 全部可答 / 可达 ∧ 无单路线锁定 ∧ 无捷径解 ∧ 类型配额满足

七个最可能被 challenge 的点，必须在发榜前给出证书

风险	可观测证据	发布门
World Index 漏页 / 解析错	分层抽样的覆盖率、字段正确率、重建 hash	ValidityGate
TWM 候选池漏证据	候选饱和曲线 + held-out 新页匹配回收率	ValidityGate
Compiler 把合理报告拒绝	合法替代层 FRR + 路线簇分层 CI	FRR gate
Judge 把空话当完成	流畅无证据 / URL dump / 局部腐蚀测试集	FAR gate
原子粒度改变分数	同义 split / merge metamorphic test	GranularityGate
fabricated URL 误杀 registry 缺失	alias / redirect / registry 修复的盲复核日志	IntegrityGate
队列	发布规则 任意一道门未通过，不得用平均分或更多样本抵消；修复测量问题后发布新版本。	

建议时间线：以验证门为节点，不以“写完代码”为节点



这不是工期承诺

每个节点都要看实测的人力、PENDING 流量和统计证书；任一 Gate 失败，时间线自动暂停。

下一个实验不是“再跑一个强 harness”，而是验证测量闭环



最后带走五句话

- 01 旧系统的 Fact / PoF / Completeness 不是都无用；它们是诊断信号，但不应用任意权重先加再乘。
- 02 DRA 的核心构念是“广度任务中，有本次交付证据地完成了多少必要研究工作”。
- 03 LoHoSearch 告诉我们：全量做轻量结构，贵的语义工作只在单题局部世界中做。
- 04 Raw GRC 用 check-level C×E + 层级聚合；确认不存在的 URL 另产生 integrity-adjusted 排名分；质量独立展示。
- 05 标准答案不是一条路线，而是一套允许替代证据、可重放、可校准的执行协议。

先一题 → 再三类 MVP → Dev-14 → 56 题 → 冻结后跑 12 harness

主要文献与内部依据

构题、广度与长程研究

- LoHoSearch, arXiv:2606.12837 (v2, 2026-06-17)
- DEEPRUBRIC, arXiv:2606.17029
- QUBRIC, arXiv:2606.03968
- WideSearch, arXiv:2508.07999
- DeepSearchQA, arXiv:2601.20975
- DeepWideSearch, arXiv:2510.20168
- DeepResearchGym, arXiv:2505.19253
- Mind2Web 2, arXiv:2506.21506

引用、信实性与冻结环境

- ALCE, arXiv:2305.14627
- FActScore, arXiv:2305.14251
- BrowseComp-Plus, arXiv:2508.06600
- DeepResearch Bench II, arXiv:2601.08536
- Correctness is not Faithfulness, arXiv:2412.18004
- FutureSearch Deep Research Bench / RetroSearch, arXiv:2506.06287
- DRA Current Method (2026-07-14)
- DRA Sandbox-native Scoring Design v3.2 (2026-07-18)
- DRA Scoring Redesign v3.3 candidate (this deck)